1 Die lineare Regressionsrechnung

Worum geht es? Die Lineare Regressionsrechnung ist ein statistisches Verfahren, welches in einer Sammlung von Daten den linearen Zusammenhang ermittelt. Damit können weitere Datenpunkte interpoliert (d.h. zwischen den bestehenden Daten berechnet) oder extrapoliert (d.h. ausserhalb der bestehenden Daten berechnet) werden.

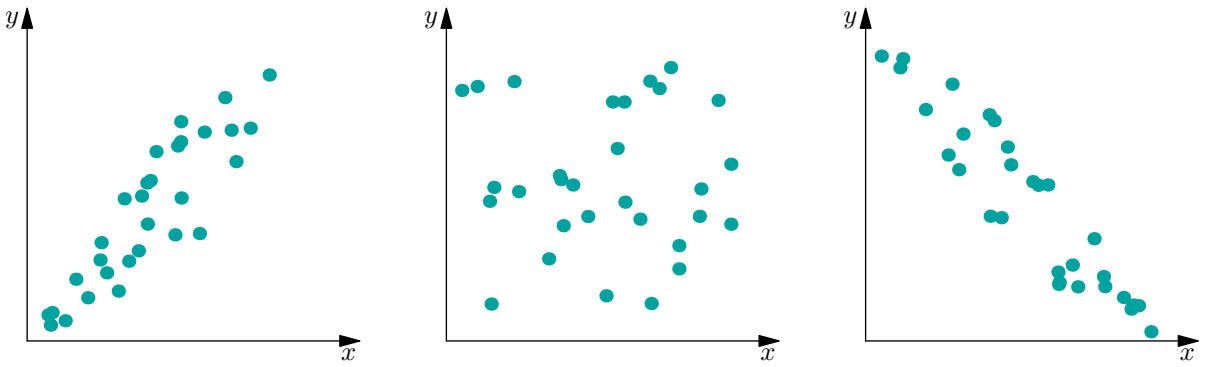
Wie wird es umgesetzt? Die eigentliche Berechnung beinhaltet mathematische Methoden, die nicht Umfang des Mathematikunterrichtes an einer BM sind. Wir sind also komplett auf unsere Taschenrechner angewiesen, welche diese Berechnung für uns vornehmen. Nichtsdestotrotz müssen wir in der Lage sein…

1. die Daten korrekt in das entsprechende Tool unseres TR einzugeben und
2. die Resultate des TR korrekt zu interpretieren.

1.1 Das Streudiagramm

Im Streudiagramm werden alle Messpunkte eingetragen. Jeder Messpunkt besitzt zwei metrische Merkmale (bspw. «Zeit, Distanz» oder «Alter, Einkommen») die eine genaue Positionierung entlang der x-, resp. y-Achse erlauben.

Der statistische Zusammenhang zwischen diesen Merkmalen ist bereits im Streudiagramm ersichtlich (siehe Abbildung 1).



(a) Positiver Zusammenhang, «wächst x, dann auch y»

(b) Kein Zusammenhang zwischen x und y

(c) Negativer Zusammenhang, «wächst x, dann fällt y»

Abbildung 1: Statistische Zusammenhänge zwischen zwei Grössen

Beispiel Von fünf Arbeitern wurden das Alter und das Einkommen in einer Tabelle erfasst und im Koordinatensystem das Einkommen in Abhängigkeit vom Alter dargestellt (siehe Abbildung 2). Das Streudiagramm zeigt, dass mit zunehmendem Alter auch das Einkommen steigt und lässt einen positivien, linearen Zusammenhang zwischen Alter und Einkommen vermuten.

1.2 Regressionsgerade

Lässt sich aus dem Zusammenhang des Streudiagrammes ein linearer Zusammenhang vermuten, so bestimmt man die Gerade, die sich im Streudiagramm von allen möglichen Geraden am

Arbeiter	Alter	Einkommen
A	21	5550
B	46	6800
C	58	7000
D	35	6200
E	28	5400

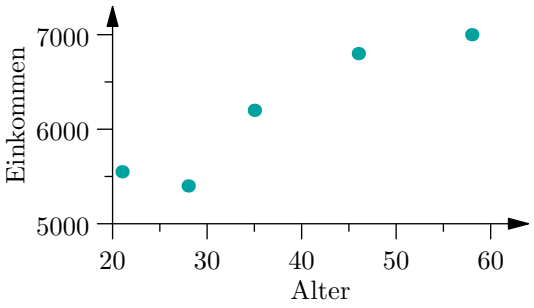


Abbildung 2: Möglicher Zusammenhang zwischen Einkommen und Alter

besten dem Datenpunktverlauf anpasst. Im einfachsten Fall geschieht dies nach Augenmass, durch Einzeichnen einer Geraden, die von den Datenpunkten möglichst wenig abweicht. Die Funktion der als *Regressionsgerade* bezeichneten Geraden bestimmen wir, indem wir die vertikalen Abstände der Punkte eines Streudiagramms zu jeder möglichen Geraden erfassen und dann unter den unendlich vielen Geraden, jene auswählen, welche die kleinste Summe der quadrierten Abstände (Abweichungen der Datenpunkte von der Regressionsgeraden sog. Residuen) aufweist, sog. Methode der kleinsten Quadrate. Mathematisch wird diese besondere Gerade als Lösung einer Extremwertaufgabe gefunden.

Abbildung 3 zeigt zwei Diagramme mit derselben Datensammlung und zwei unterschiedlichen Geraden. Die Abstände zwischen der Geraden und den Datenpunkten ist hervorgehoben und lässt klar erkennen, dass die rechte Gerade *besser* ist als die linke, da die Summe der Abstände kleiner ist. Die Gerade, bei welcher die Summe der Abstände minimal ist, ist die gesuchte Regressionsgerade.

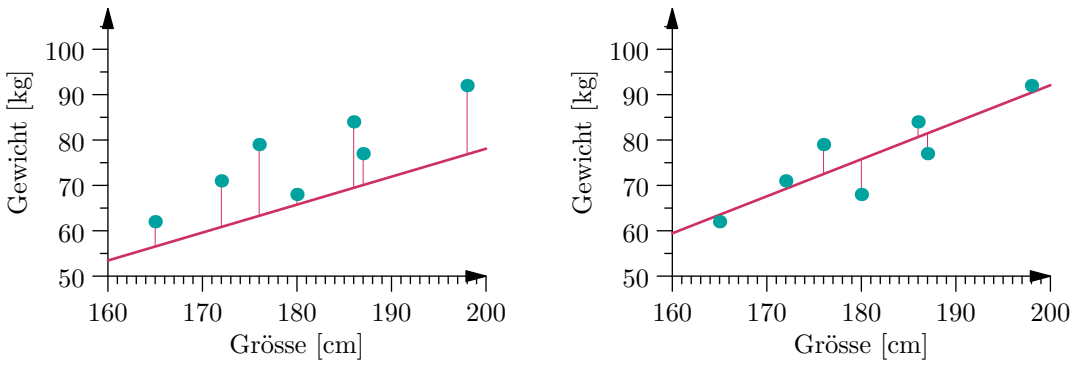


Abbildung 3: Gleiches Streudiagramm mit zwei unterschiedlichen Geraden

1.3 Vorgehen anhand eines Beispiels

Die folgenden Abschnitte zeigen anhand eines Beispiels das Vorgehen um eine lineare Regression zu rechnen.

1.3.1 Datensammlung

Ausgangspunkt ist eine Tabelle, welche die zu analysierenden Daten enthält. Dies können bspw. physikalische Messdaten oder Auszüge aus einer Buchhaltung, etc. sein. Als Beispiel dienen uns die Daten in Tabelle 1, welche in einem Freibad aufgezeichnet wurden. Wir möchten daraus

Temperatur (°C)	x	28	23	32	35	29	30	27	34	32
Gästezahl	y	400	60	630	560	290	620	440	610	250

Tabelle 1: Ausgangsdaten

ermitteln, ob es einen linearen Zusammenhang zwischen Temperatur und Anzahl Gäste im Freibad gibt, wie stark dieser Zusammenhangt ist und wieviel Gäste an einem Tag mit 33 °C zu erwarten sind.

1.3.2 Abhängige/unabhängige Variable bestimmen

Wir gehen davon aus, dass die Anzahl Gäste von der Temperatur bestimmt wird (im Sinne von «je wärmer, desto mehr Gäste»). Das heisst, dass die Daten auf der Zeile *Temperatur* mit der unabhängigen Variable x und die Daten bei *Gästezahl* abhängigen Variable y identifiziert werden.

1.3.3 Streudiagramm erstellen

Mit dem Streudiagramm wird eine erste Visualisierung der Daten vorgenommen (siehe Abbildung 4). Jeder Messpunkt in der Tabelle 1 kann über seinen x-, resp. y-Wert in ein Koordinatensystem eingetragen werden. Die Punkte werden *nicht* miteinander verbunden!

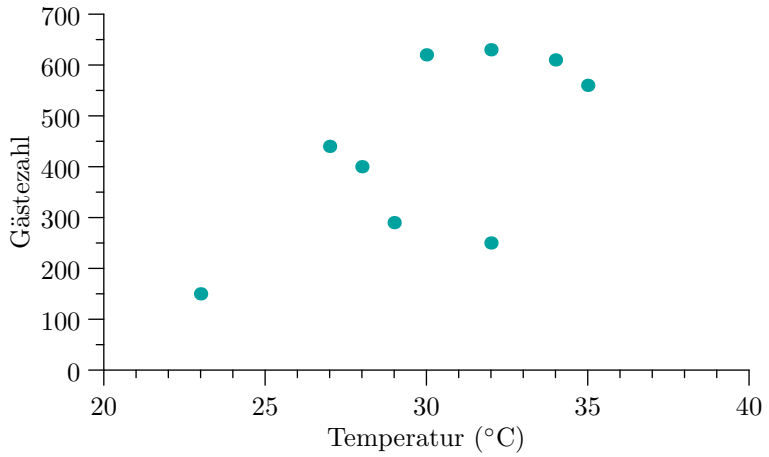


Abbildung 4: Streudiagramm

1.3.4 Regressionsgerade berechnen (lassen)

Mit dem Rechner wird nun die Regressionsgerade berechnet, also jene Lineare Funktion, welche den kleinsten Abstand zu den Datenpunkten hat. Das Resultat ist eine Funktion der Form $f(x) = ax + b$, konkret für unser Beispiel:

$$f(x) = 31.6x - 509.3$$

1.3.5 Streudiagramm mit Regressionsgeraden ergänzen

Die berechnete Gerade kann nun als zusätzliche Information in das Streudiagramm eingezeichnet werden. Dabei wählt man zwei Werte auf der x-Achse, die genügend weit auseinander liegen (im Beispiel 20 und 38), berechnet die jeweiligen y-Werte und zeichnet dann die Gerade ein (siehe Abbildung 5).

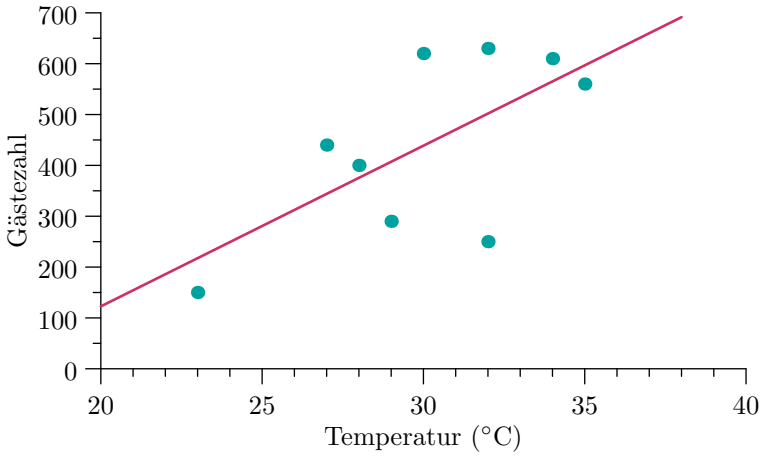


Abbildung 5: Streudiagramm mit Regressionsgeraden

1.3.6 Regression bewerten

Man sieht den Daten in Abbildung 5 relativ gut an, dass die berechnete Gerade ein bisschen, aber nicht wirklch gut zu den Daten passt (dafür müssten die Messpunkte viel näher an der Geraden liegen). Der Rechner liefert uns zusätzlich einen Wert (den sog. Korrelationsfaktor r), mit welchem die Qualität der Regression beurteilt werden kann. Als Faustregel gelten die Angaben in Tabelle 2. Unser Beispiel liefert einen Korrelationsfaktor r von 0.661 – also knapp auf der Schwelle zu einem starken Zusammenhang.

Bereich	Bedeutung
$0.0 \leq \lvert r \rvert < 0.2$	schwacher Zusammenhang
$0.2 \leq \lvert r \rvert < 0.6$	mittlerer Zusammenhang
$0.6 \leq \lvert r \rvert < 1.0$	starker Zusammenhang
$\lvert r \rvert = 1.0$	vollständiger Zusammenhang

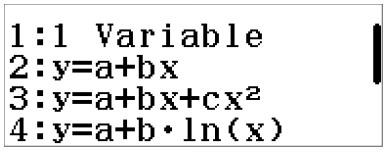
Tabelle 2: Bewertung des Korrelationsfaktors

1.4 Berechnung mit dem CASIO fx-991 DE X

Wechsel zum Statistik-Programm Wichtig: Wird das Statistik-Programm via MENU verlassen, gehen die eingegebenen Daten verloren!

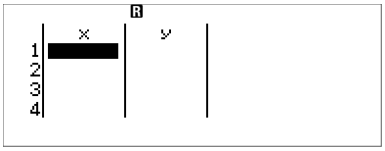
MENU 6 2





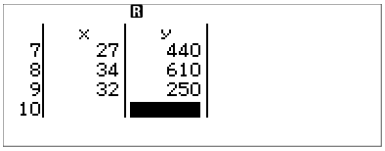
Eingeben der Daten Im Statistik-Editor können nun die Daten eingetragen werden. Die Reihenfolge der Daten spielt dabei keine Rolle.

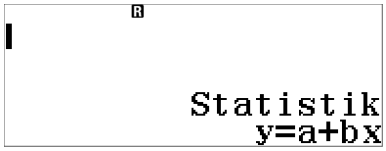
0-9 ◀ ▲ ▶ ▼



Abschliessen der Eingabe Mit AC verlässt man den Statistik-Editor und gelangt in einen Modus, in dem die üblichen Rechenfunktionen wieder verfügbar sind - die statistischen Daten bleiben erhalten.

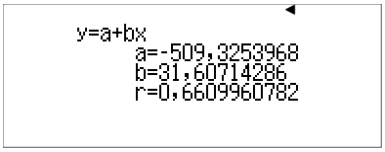
AC





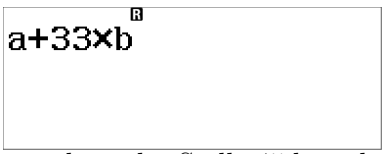
Berechnen der Regressionsdaten In diesem Bild sieht man nun die berechneten Angaben zur linearen Funktion (a und b) und den Korrelationsfaktor r.

OPTN 3



Rechnen mit den Regressionsdaten Man kann die Variablen a und b in eigene Formeln einbinden und damit rechnen. Ich zeige beispielhaft, wie man $a + 33b$ auswerten kann und auch, wie darauf aufbauend weitere Berechnungen gemacht werden können.

OPTN ▼ 4 1 + 33 ×
OPTN ▼ 4 2 =



Will man jetzt die Funktion auch an der Stelle 45 berechnen, navigiert man mit den Pfeiltasten in die letzte Berechnung und ersetzt die 33 mit 45.

◀, ◀ ▶ DEL 0-9, =



Editieren der Daten Die eingegebenen Daten können jederzeit ergänzt, verändert oder gelöscht werden. Dadurch verändern sich mit grosser Wahrscheinlichkeit die Regresssionsparameter und müssen neu berechnet werden.

OPTN 4

