Lineare Regression

Teil des Weiterbildungskurses in angewandter Statistik

der ETH Zürich

Folien

Werner Stahel, Oktober 2015

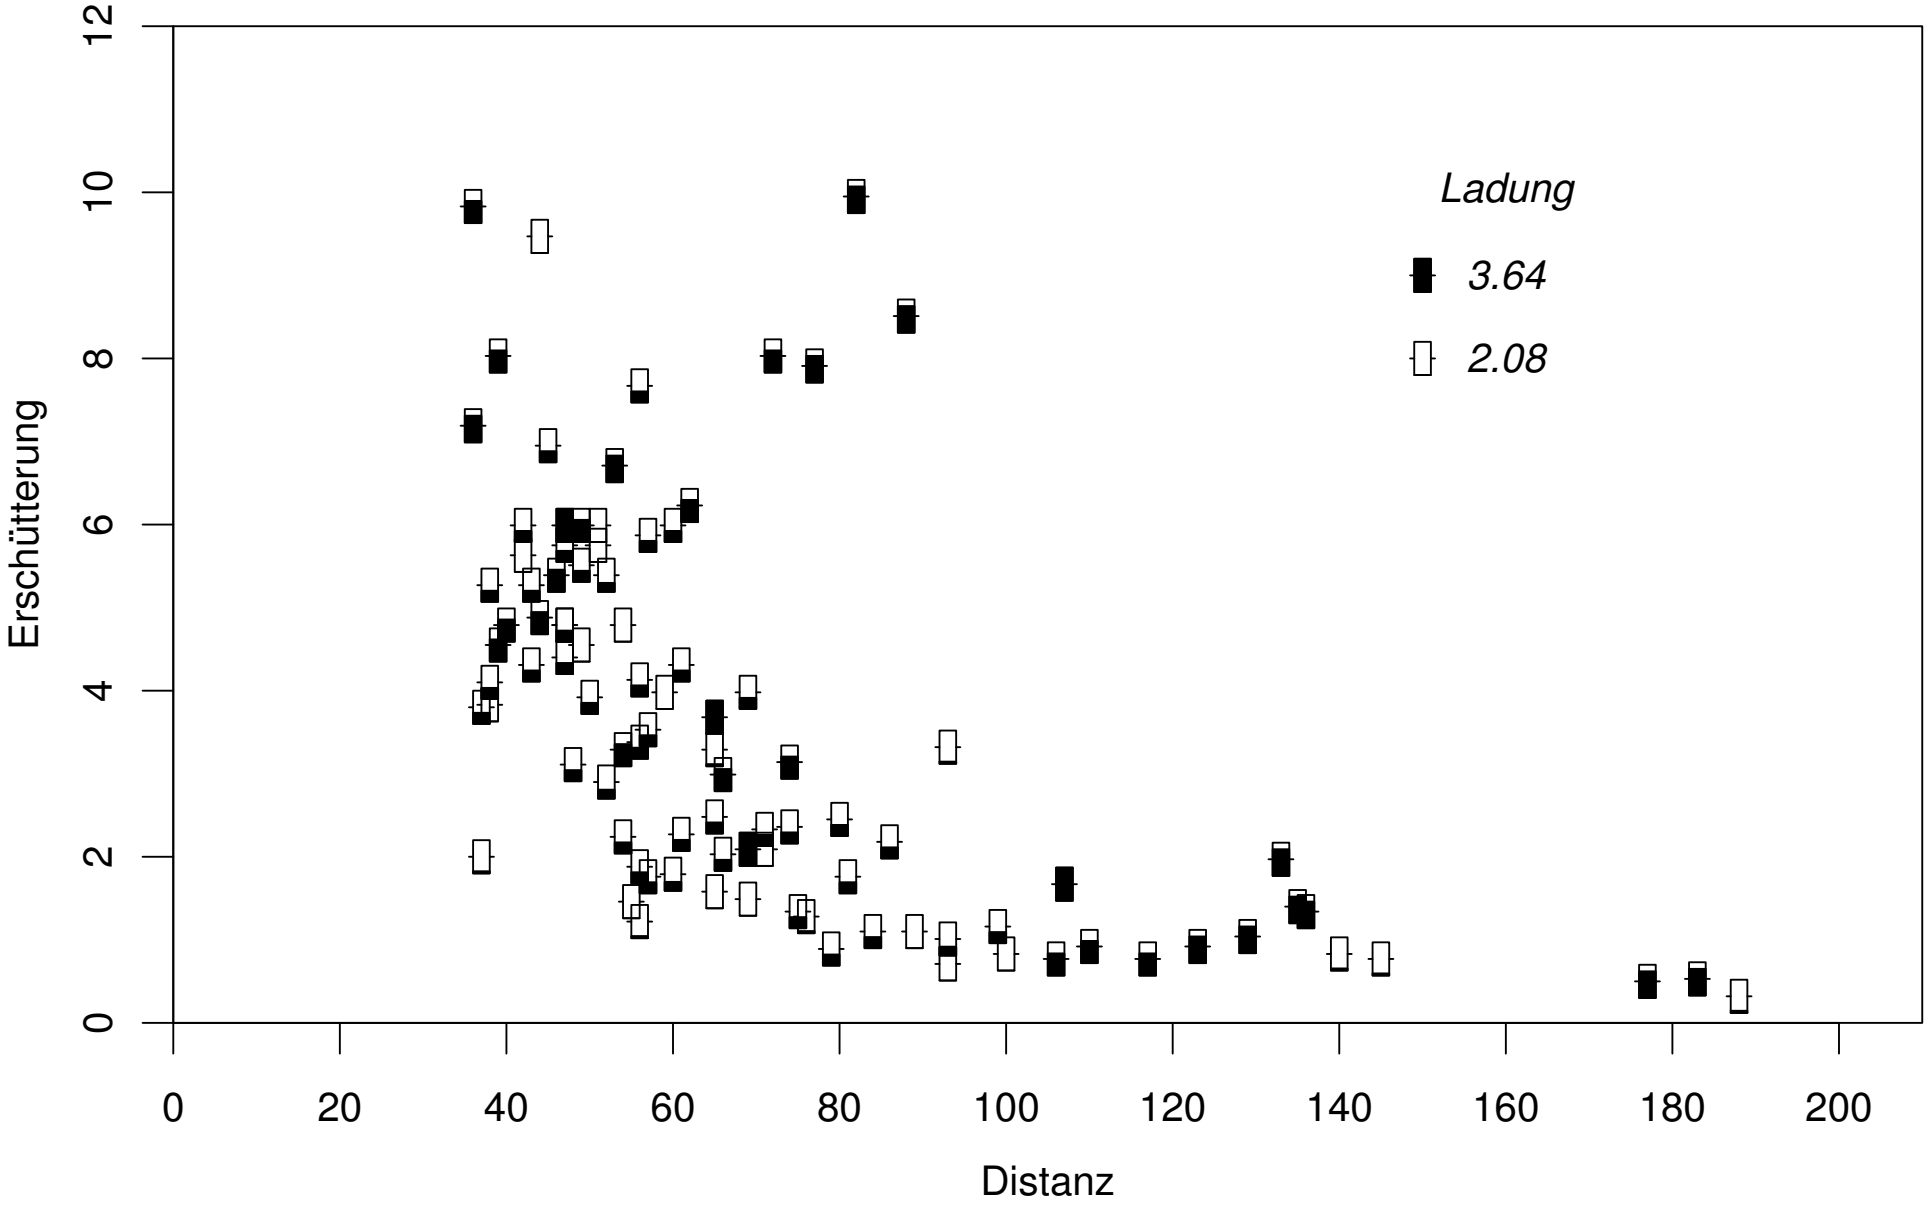
REGRESSION 1: Multiple ineare Regression

1 Einführung in die statistische Regressionsrechnung

1.1 Beispiele zur linearen Regression

b Beispiel Sprengungen.

Erschütterung $\approx$ Funktion $\langle$Ladung, Distanz, Spreng-Sit., Untergrundart$\rangle$


Erschütterung
0
2
4
6
8
10
12
0
20
40
60
80
100
120
140
160
180
200
Distanz
Ladung
3.64
2.08

1.1

c Y : Zielgrösse

$x^{(1)}, x^{(2)}, \ldots, x^{(m)}$: Eingangsgrössen oder erklärende Variable

$$Y_i = h\langle x_i^{(1)}, x_i^{(2)}, \ldots, x_i^{(m)} \rangle + E_i$$

h : Regressionsfunktion, E_i : Zufallsabweichung

Einfachster Fall: 1 erklärende Variable

linearer Zusammenhang: $h\langle x \rangle = \alpha + \beta x$

$$Y_i = \alpha + \beta x_i + E_i$$

1.1

d Beispiel Schadstoffe im Tunnel.

Y_i : Schadstoff-Emission pro Kilometer,
$x_i^{(1)}$: Anzahl "'Nicht-Lastwagen"',
$x_i^{(2)}$: Anzahl Lastwagen.

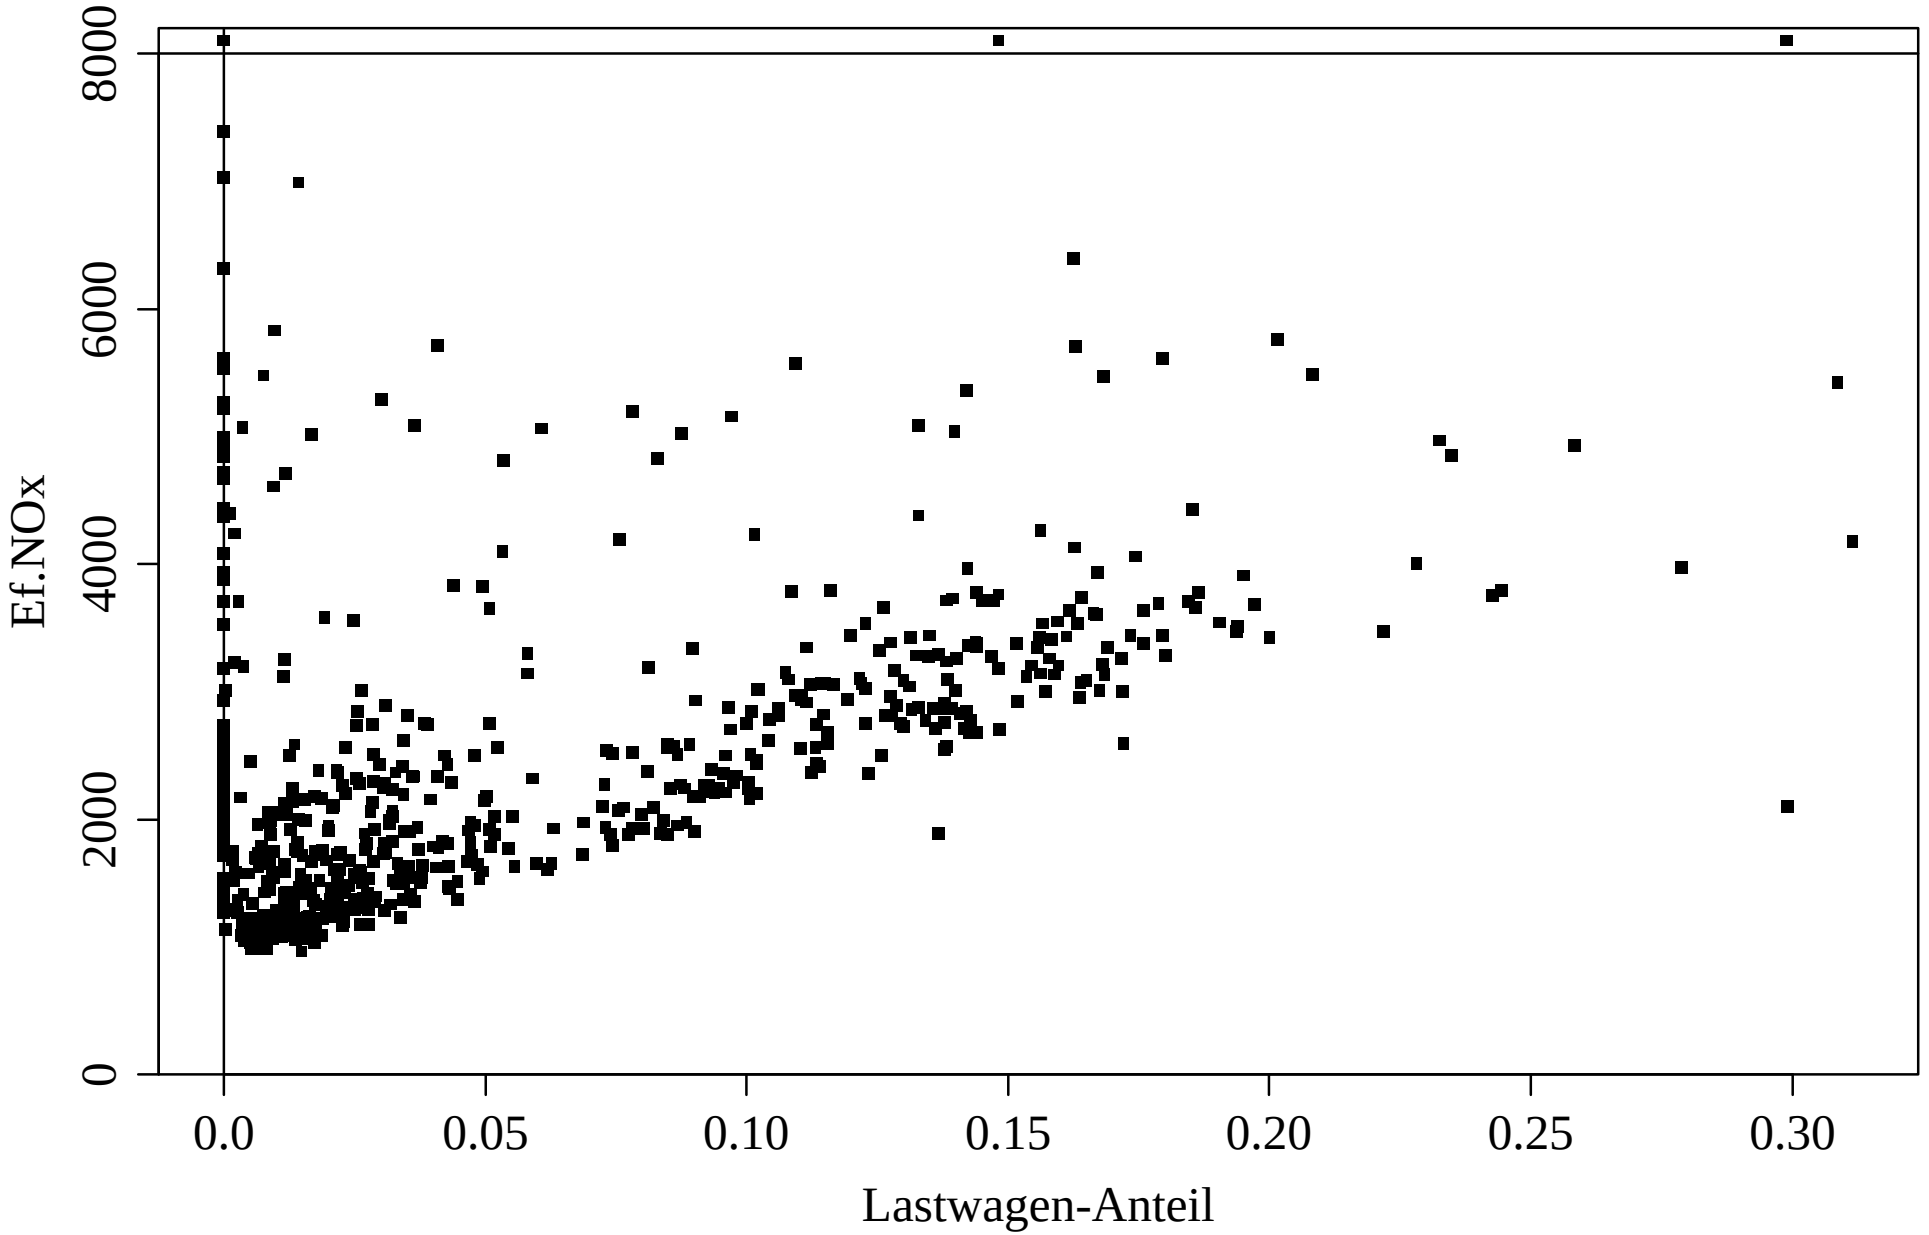
$$Y_i = \beta_1 x_i^{(1)} + \beta_2 x_i^{(2)} + E_i$$

β_1 (β_2) : durchschn. Emission pro Nicht-Lastwagen (Lastwagen)

Dividieren durch Fahrzeugzahl $x_i^{(1)} + x_i^{(2)}$

$$\begin{aligned} \widetilde{Y}_i &= \beta_1 \widetilde{x}_i^{(1)} + \beta_2 \widetilde{x}_i^{(2)} + \widetilde{E}_i = \beta_1 \widetilde{(1 - x_i^{(2)})} + \beta_2 \widetilde{x}_i^{(2)} + \widetilde{E}_i \\ &= \beta_1 + (\beta_2 - \beta_1)\, \widetilde{x}_i^{(2)} + E_i = \alpha + \beta \widetilde{x}_i^{(2)} + E_i \end{aligned}$$

$\longrightarrow$ einfache linere Regression!


Ef.NOx
0
2000
4000
6000
8000
0.0
0.05
0.10
0.15
0.20
0.25
0.30
Lastwagen-Anteil

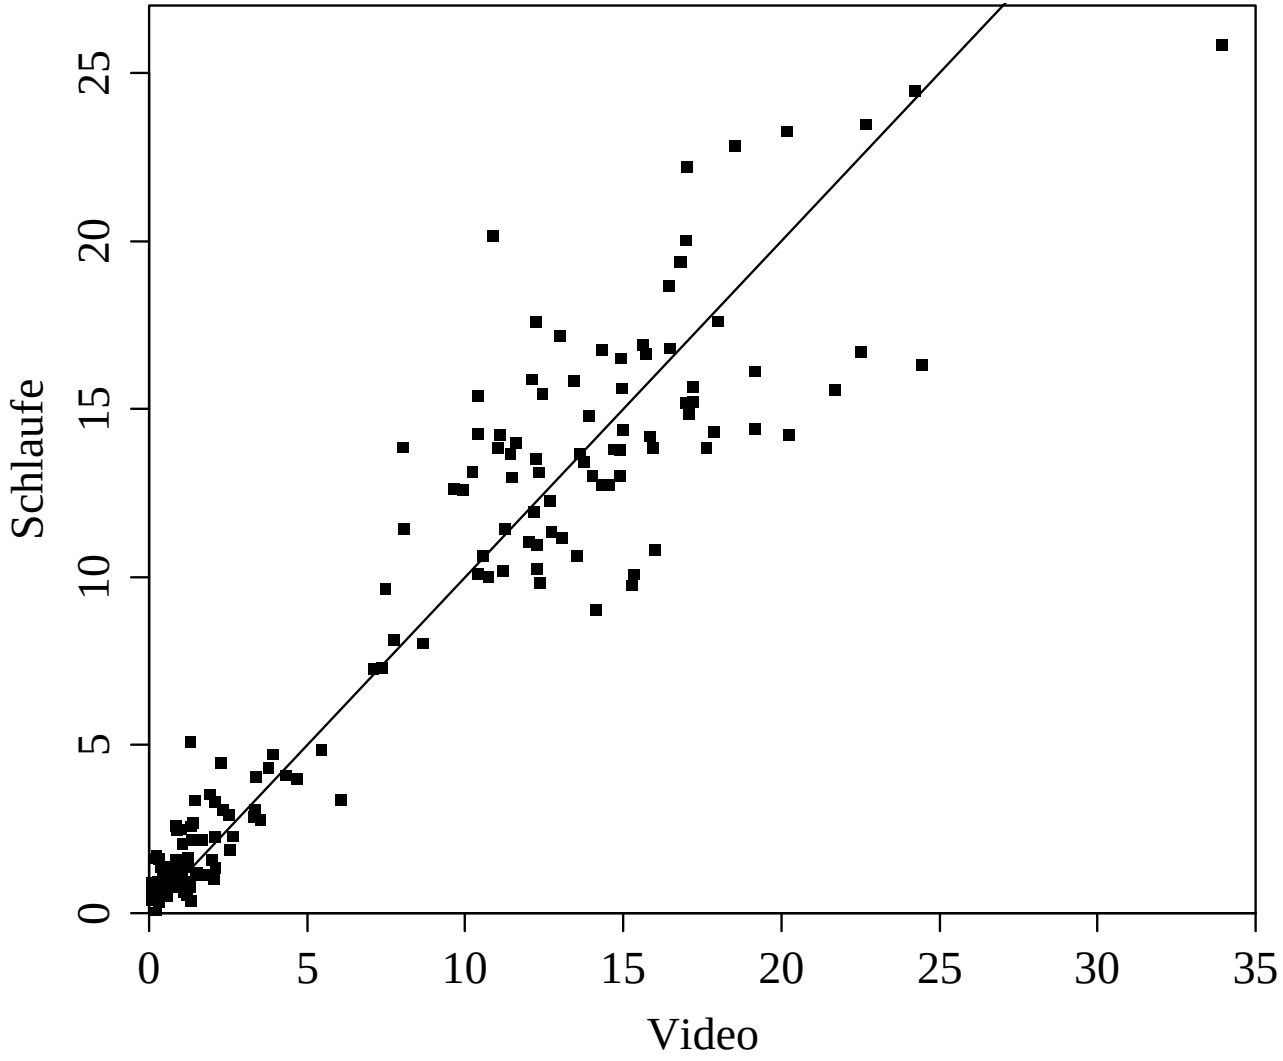
1.1

e Beispiel Lastwagen-Anteil.

Y_i Anteil der Lastwagen gemäss Schlaufen-Detektor

x_i Anteil der Lastwagen gemäss Video-Auszählung

Eichung



1.1

f Beispiel Antikörper-Produktion.

Y : Produktion von Antikörpern in Zellen,

die Mäusen injiziert werden.

$x^{(j)}$: 4 "'Prozess-Faktoren"'

Experiment braucht viele Mäuse,

ist zeitaufwendig und kostet Geld.

Sparen durch Versuchsplanung!

Phase 1: Wichtige Faktoren finden.

g Phase 2: Optimale Einstellungen dieser Faktoren finden.

1.1

h Fragestellungen:

1. Vorhersage, Prognose, Interpolation.

   Sprengungen: für geg. Distanz und Ladung die Erschütterung „vorhersagen".

   Obere Grenze?

2. Schätzung von Parametern.

   Gubrist-Tunnel: Emissionsfaktoren für Lastwagen und für übrige Fahrzeuge.

3. Bestimmung von Einflussgrössen.

   Antikörper-Produktion, Phase 1: Wichtige Faktoren finden.

   Forschungs-Projekte: Von welchen Grössen wird Y eigentlich beeinflusst?

4. Optimierung.

   Antikörper-Produktion, Phase 2: Optimale Einstellungen.

5. Eichung.

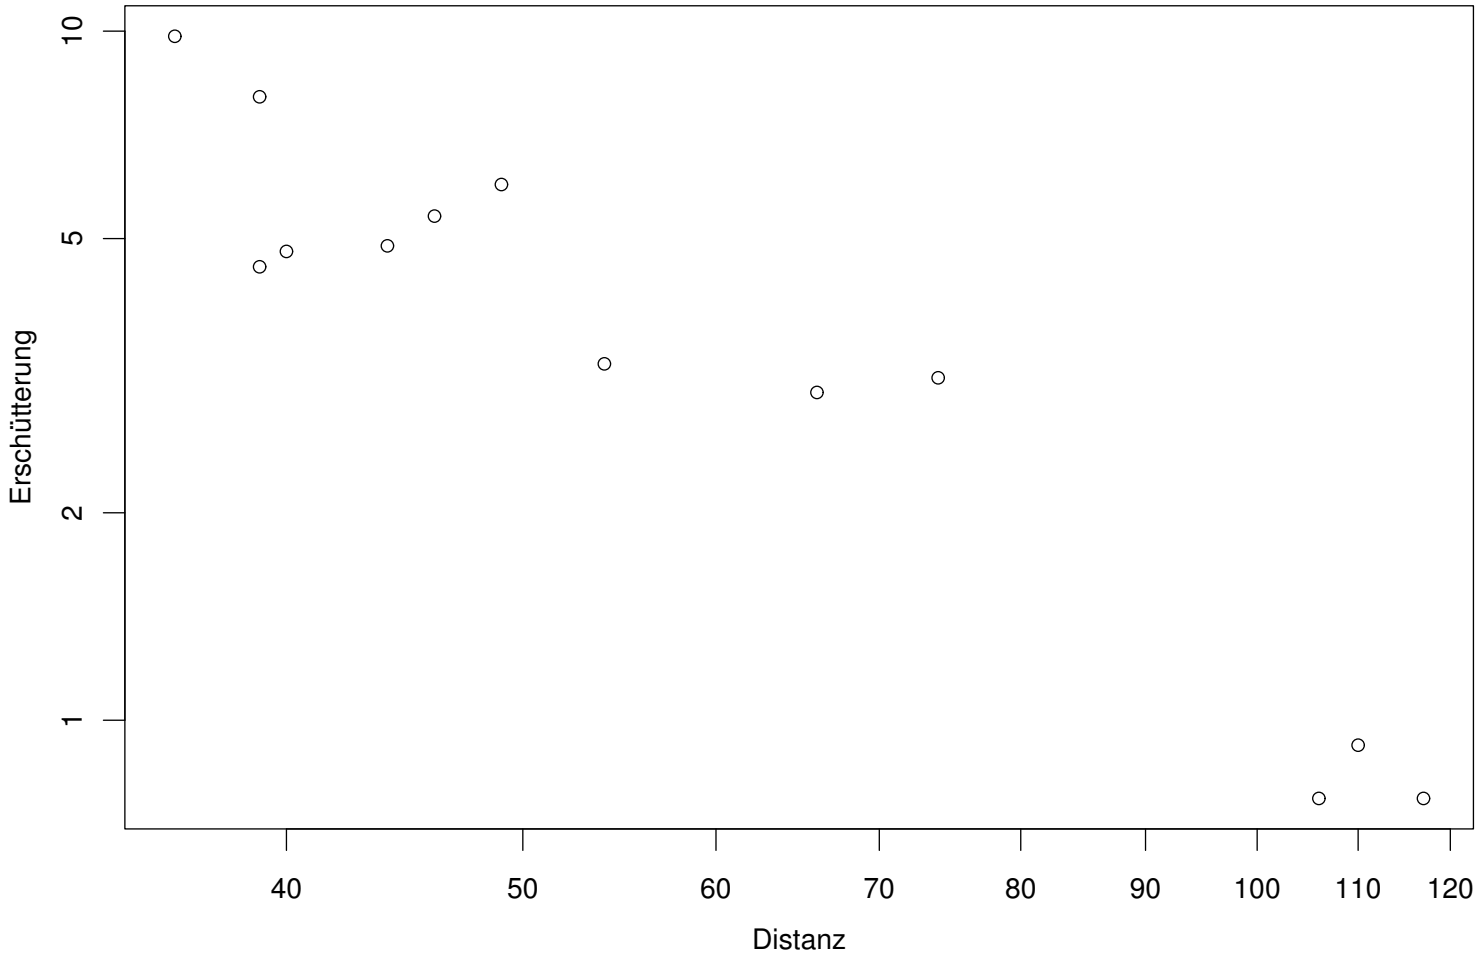
   Beispiel Lastwagen-Anteil:

   Systematische Überschätzung durch Schlaufen-Detektor korrigieren.

   Häufig: Messinstrumente.

2 Einfache lineare Regression

2.1 Das Modell



2 Einfache lineare Regression

2.1 Das Modell

a Beispiel Sprengungen.

$$\log\langle \texttt{Erschütterung} \rangle \approx \alpha + \beta \log\langle \texttt{Distanz} \rangle$$

c $\texttt{Erschütterung} \approx \gamma\, \texttt{Distanz}^{\beta}$ mit $\gamma = 10^{\alpha}$.

d Gerade $y = \alpha + \beta x$.

α: Achsenabschnitt, β: Steigung

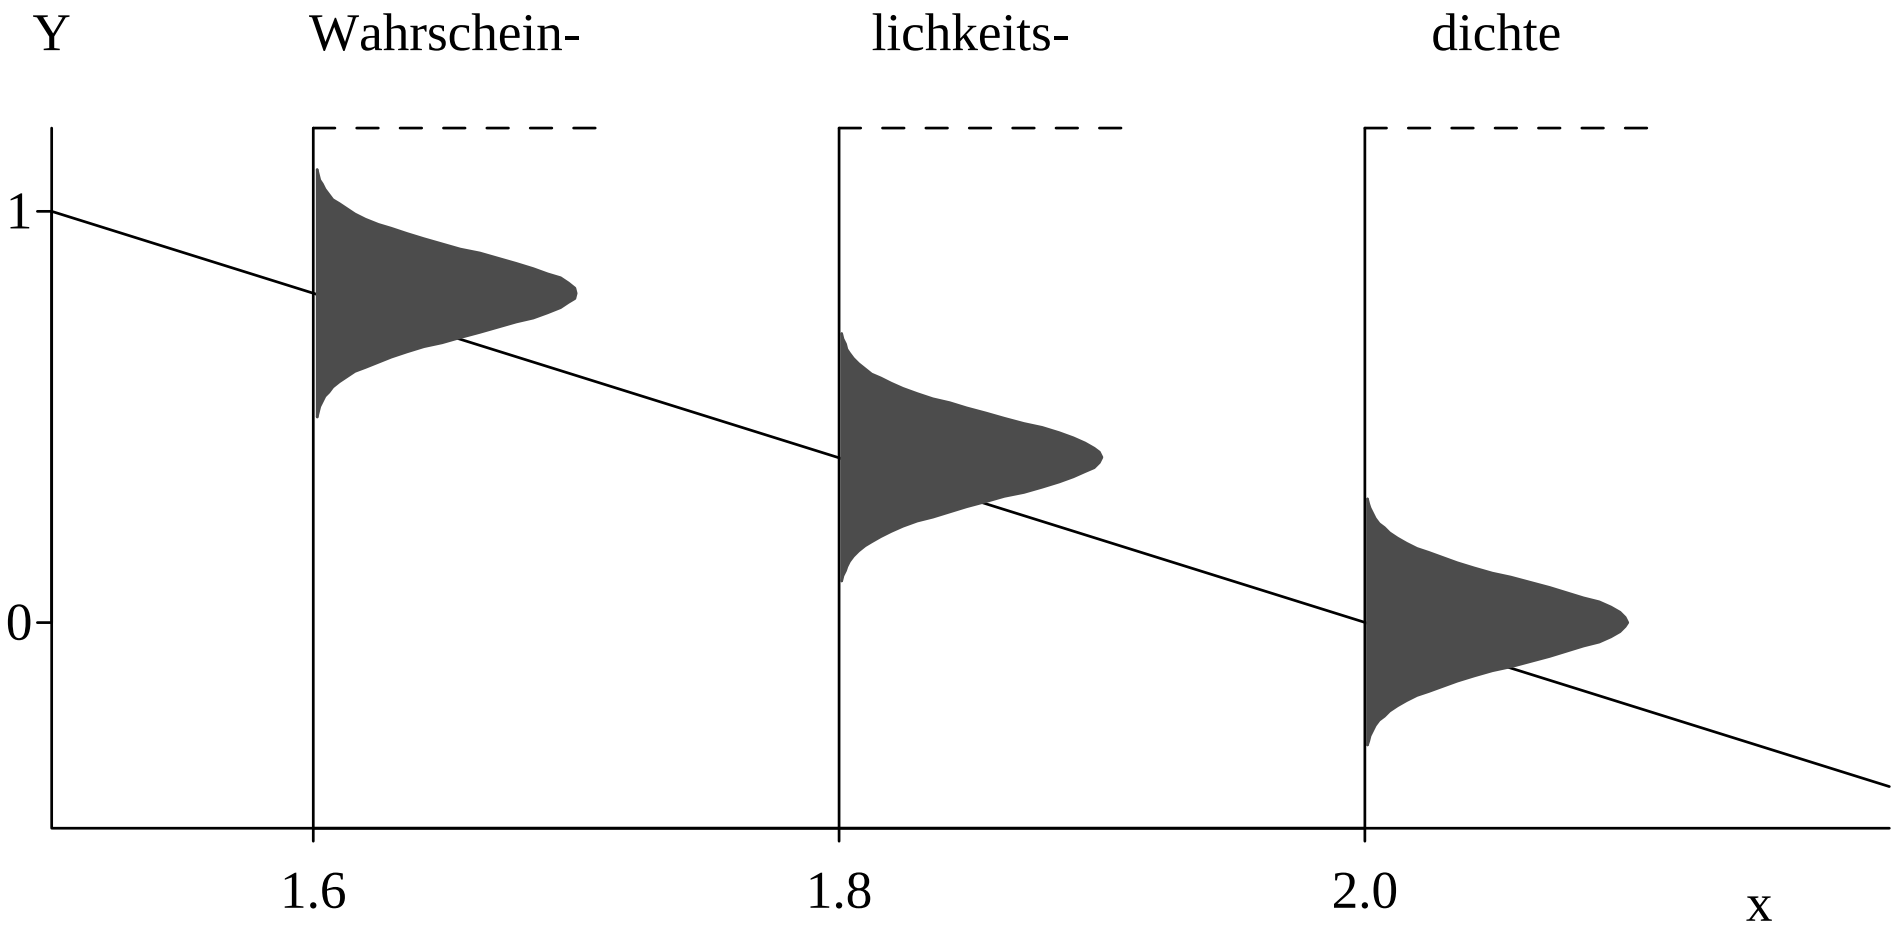
e Im Streudiagramm: Gerade legen!

f Modell: $Y_i = \alpha + \beta x_i + E_i \qquad E_i \sim \mathcal{N}\langle 0, \sigma^2 \rangle$

g Die drei Grössen α, β und σ sind die Parameter des Modells.

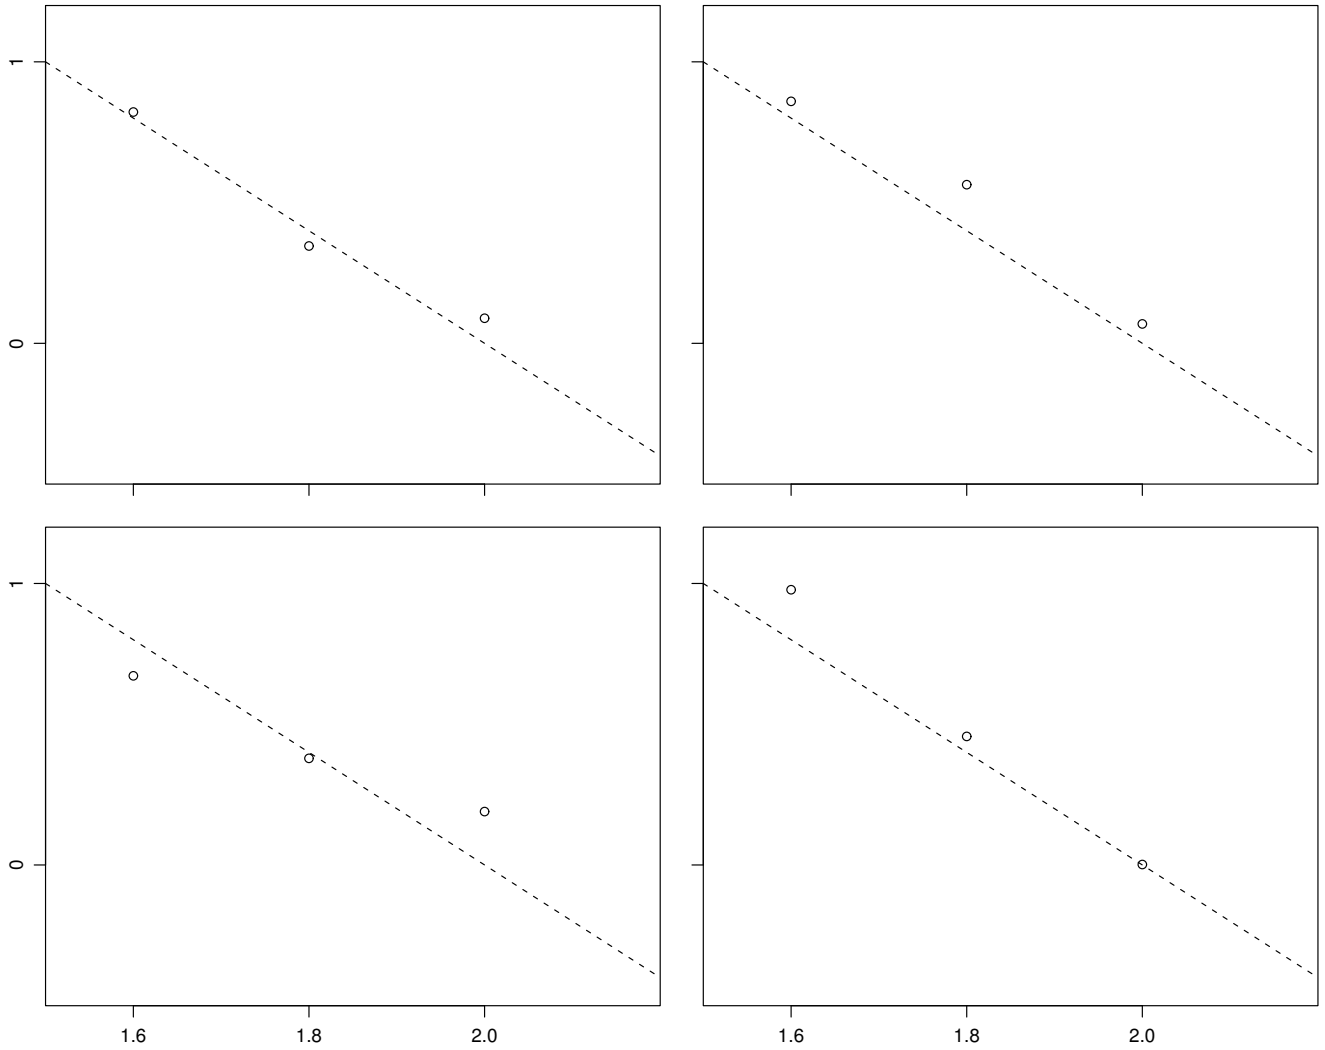
2.1

h Veranschaulichung des Modells.

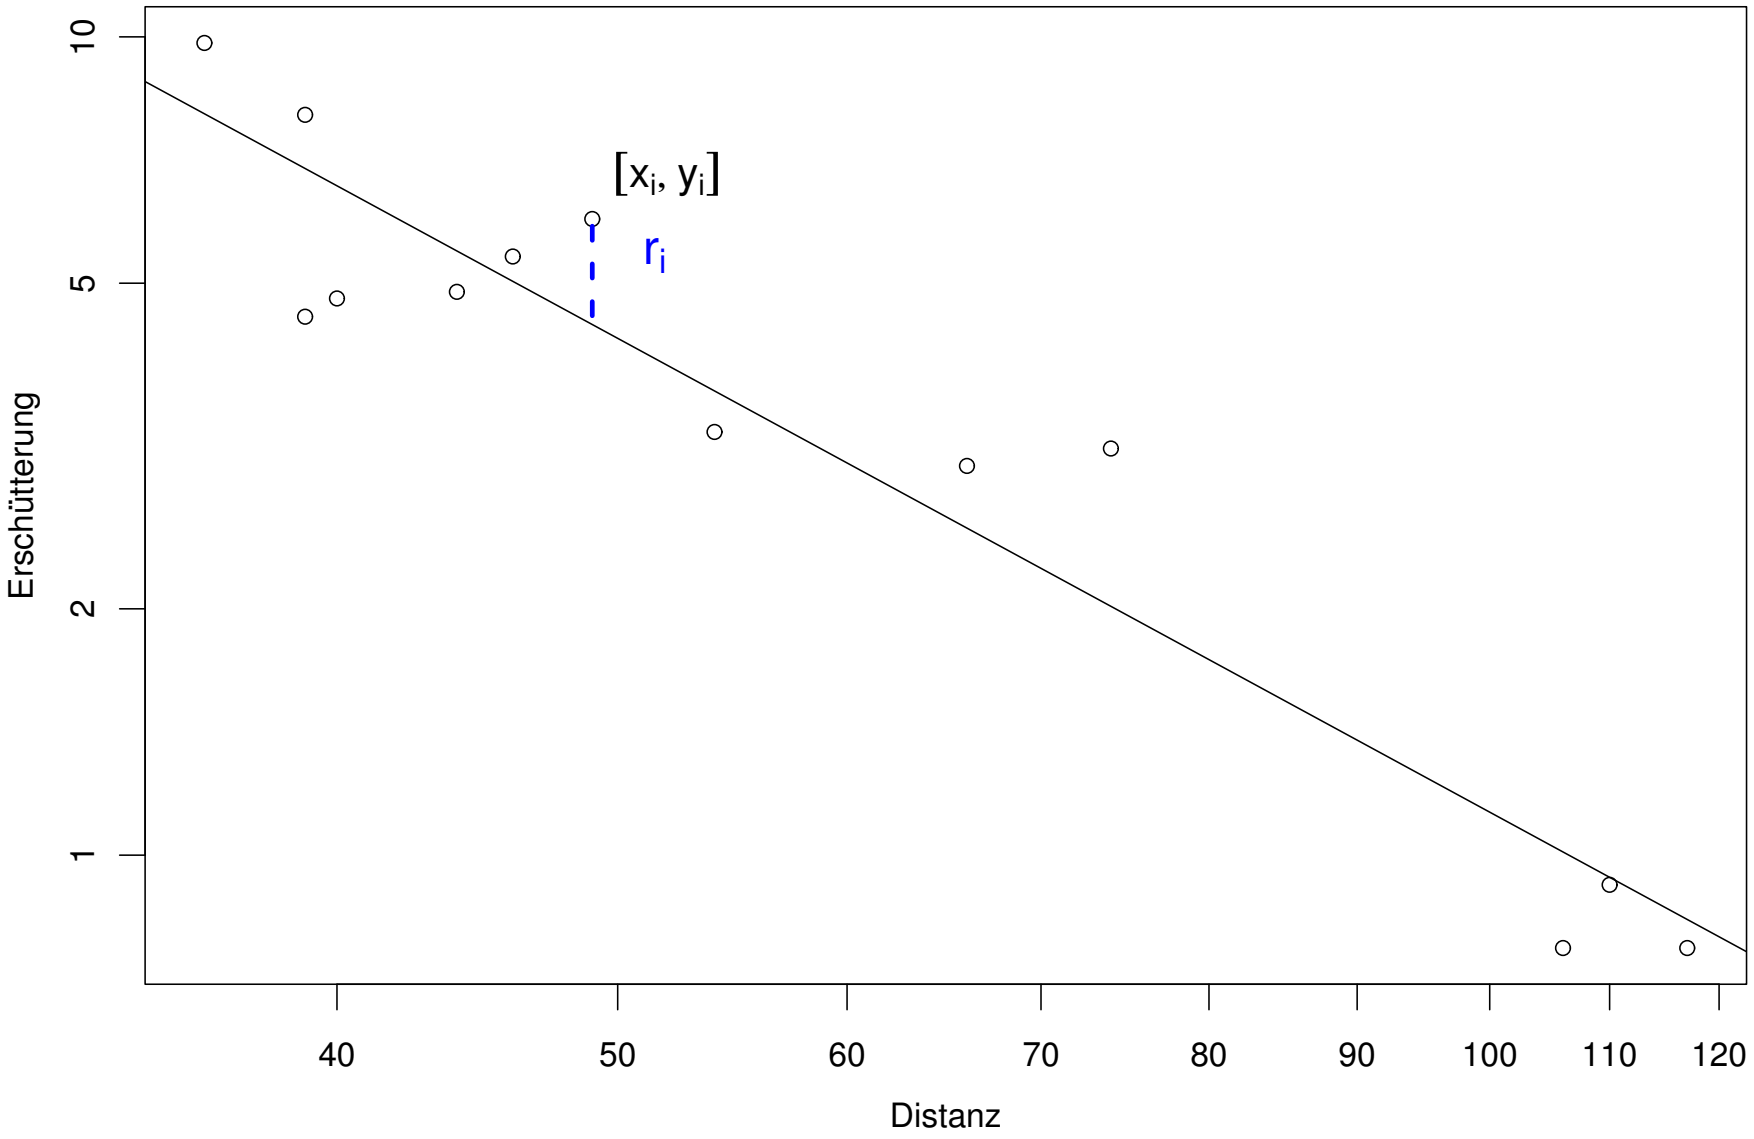


2.1

i Zufallszahlen



2.2 Schätzung der Parameter



2.2

c Kleinste Quadrate: Die Parameter werden so bestimmt,

dass die Summe der quadrierten Abweichungen r_i,

$$\sum_{i=1}^{n} r_i^2 \ , \qquad r_i = y_i - (\alpha + \beta x_i)$$

minimal wird. $\longrightarrow$

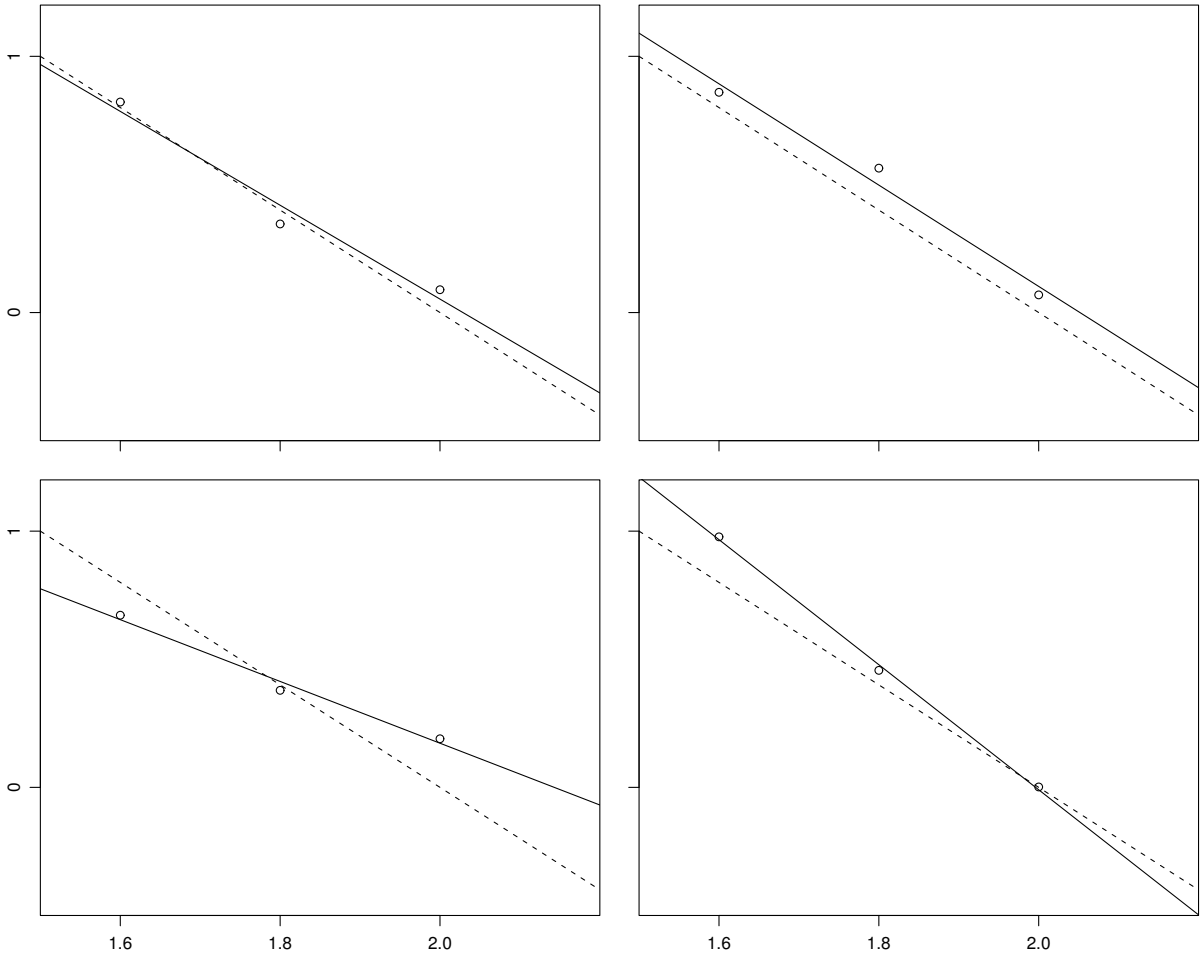
$$\widehat{\beta} = \sum_{i=1}^{n} (x_i - \bar{x})(Y_i - \overline{Y}) \Big/ \sum_{i=1}^{n} (x_i - \bar{x})^2 \qquad \widehat{\alpha} = \overline{Y} - \widehat{\beta}\bar{x}$$

= Maximum Likelihood

2.2

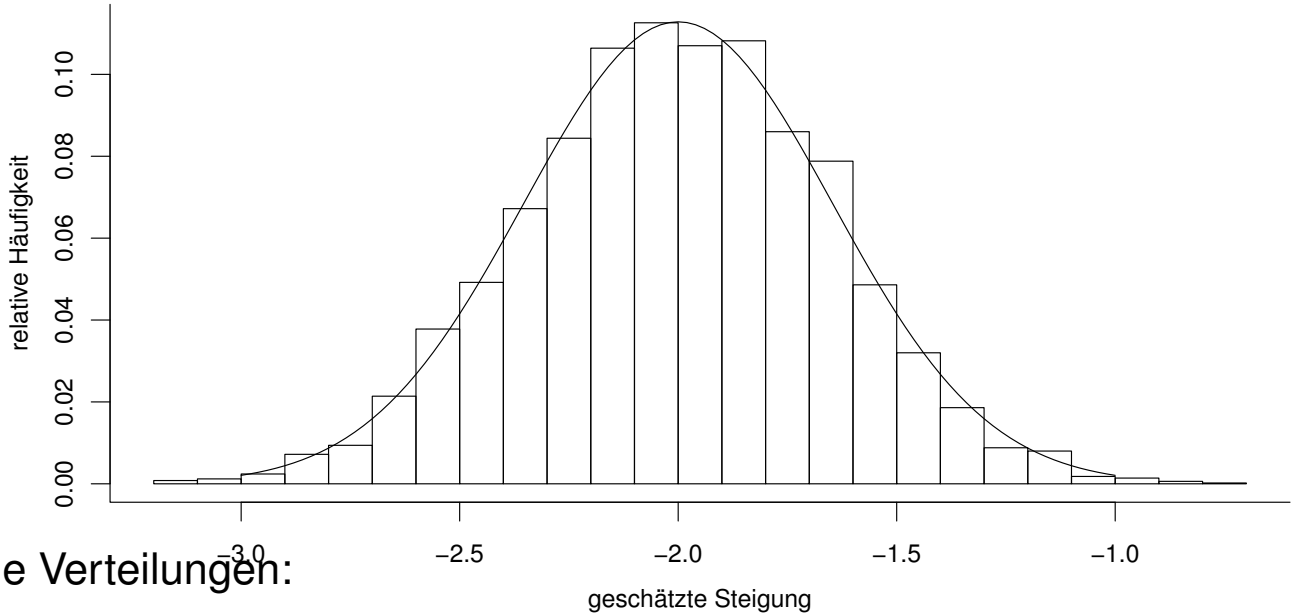
f Schätzungen sind Zufallsvariable. Bezeichnung: $\widehat{\alpha}$, $\widehat{\beta}$.

Zufallsvariable streuen.



2.2

h Simulierte Verteilung



i Theoretische Verteilungen:

$$\widehat{\beta} \sim \mathcal{N}\langle \beta, \sigma^2 / \mathrm{SSQ}^{(X)} \rangle$$

$$\widehat{\alpha} \sim \mathcal{N}\left\langle \alpha\,,\, \sigma^2 \left(\frac{1}{n} + \bar{x}^2\right) \middle/ \mathrm{SSQ}^{(X)} \right\rangle$$

$$\mathrm{SSQ}^{(X)} = \sum_{i=1}^{n} (x_i - \bar{x})^2$$

2.2

k Eigenschaften von Schätzungen:

Erwartungstreue?

l Mittlerer quadratischer Fehler, Varianz der Schätzung?

n Die Kleinste-Quadrate-Schätzungen $\widehat{\alpha}$ und $\widehat{\beta}$ sind

- erwartungstreu & normalvert. mit den angeg. Varianzen,
- die besten Schätzungen

sofern die Zufallsfehler unabhängig sind und

alle die gleiche Normalverteilung $\mathcal{N}\langle 0, \sigma^2 \rangle$ haben.

Sonst sind andere Schätzungen besser!

2.2

- Schätzung von $\sigma^2 = \mathrm{var}\langle E_i \rangle$.

$$E_i \approx R_i = Y_i - (\widehat{\alpha} + \widehat{\beta} x_i) = Y_i - \widehat{y}_i$$

Residuen R_i, angepasste Werte (fitted values, fit) $\widehat{y}_i$

$$\widehat{\sigma}^2 = \frac{1}{n-2} \sum_{i=1}^{n} R_i^2$$

Drei Grundfragen der Schliessenden Statistik

1. Welcher Wert ist ist für den (jeden) Parameter

   am plausibelsten?

   $\longrightarrow$ Schätzung

2. Ist ein bestimmter Wert plausibel?

   $\longrightarrow$ Test.

3. Welche Werte sind insgesamt plausibel?

   $\longrightarrow$ Vertrauens- oder Konfidenzintervall

2.3 Tests und Vertrauensintervalle

b Nullhypothese H_0: $\beta = -2$ ... oder vollständig:

Die Beobachtungen folgen dem Modell der einfachen linearen Regression

mit $\beta = -2$ und beliebigem α und σ.

Alternativen H_A: einseitig $\beta > -2$ oder zweiseitig $\beta \neq -2$.

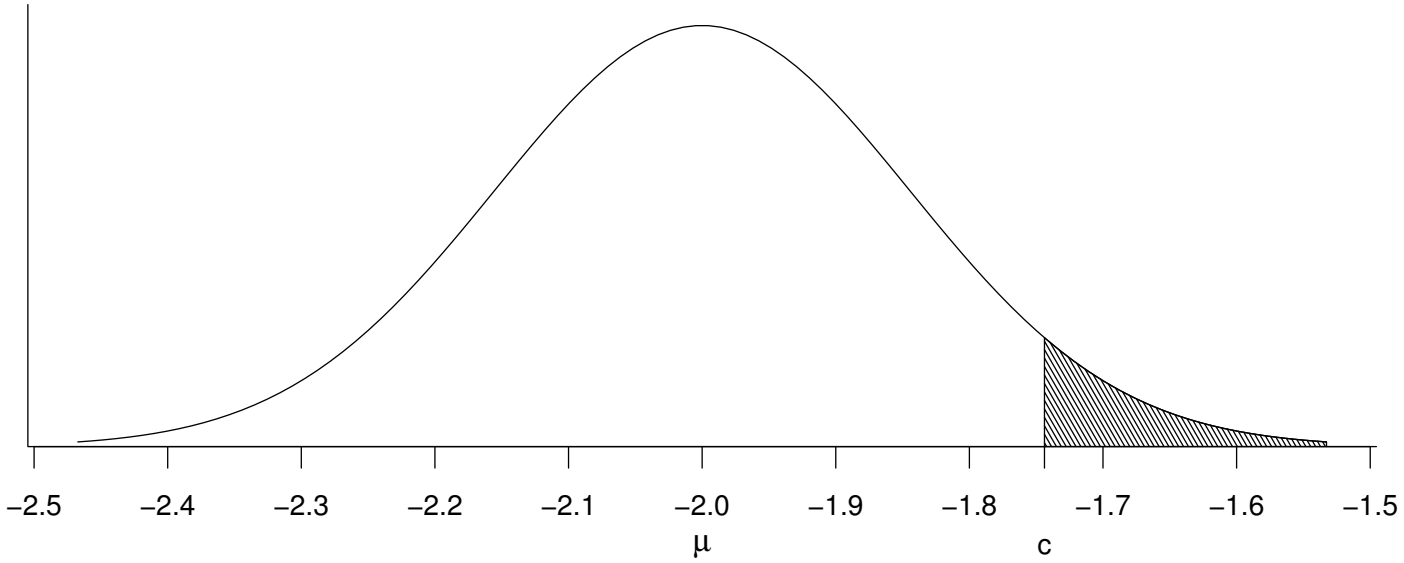
Test-Statistik: = Schätzung $\widehat{\beta}$

$(\widehat{\beta} - \beta_0) \sim \mathcal{N}\langle 0, \mathrm{se}^{(\beta)\,2}\rangle \qquad \mathrm{se}^{(\beta)\,2} = \widehat{\sigma}^2 / \mathrm{SSQ}^{(X)}$

$T = (\widehat{\beta} - \beta_0) \,/\, \mathrm{se}^{(\beta)} \sim \text{t-Vert.}_{n-2}$

Verteilung der Test-Statistik unter der Nullhypothese

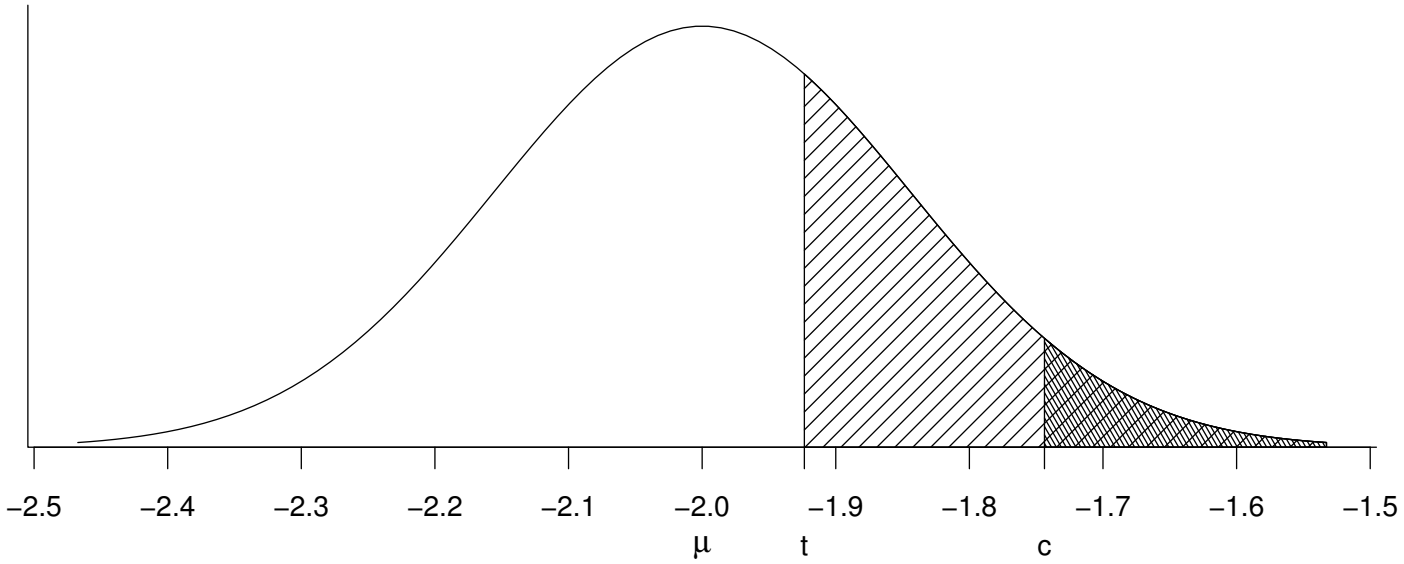
$T = (\widehat{\beta} - \beta_0) \,/\, \mathrm{se}^{(\beta)} \sim$ t-Vert.$_{n-2}$



$\longrightarrow$ Kritischer Bereich $T > c$.

2.3

c $T = (\widehat{\beta} - \beta_0) \,/\, \mathrm{se}^{(\beta)} \sim$ t-Vert.$_{n-2} \longrightarrow$ P-Wert.



H_0 meistens: $\beta = 0 \longrightarrow$ P-Wert aus Programm.

2.3

d Computer-Output.

Regression Analysis - Linear model: Y = a+bX

Dependent variable: log10(ersch) Independent variable: log10(dist)

Parameter	Estimate	Standard Error	T Value	Prob. Level
Intercept	$\widehat{\alpha} =$ 3.8996	$\mathrm{se}^{(\alpha)} =$ 0.3156	$T^{(\alpha)} =$ 12.36	0
Slope	$\widehat{\beta} =$ –1.9235	$\mathrm{se}^{(\beta)} =$ 0.1783	$T^{(\beta)} = -10.79$	0

R-squared = 0.9136 $= r^2_{XY}$
Std.dev. of Error $= \widehat{\sigma}$ = 0.1145 on $n - 2 =$ 11 degrees of freedom
F-statistic: 116.4 on 1 and 11 degrees of freedom, the p-value is 3.448e-07

2.3

f Vertrauensintervall: Der Annahmebereich war

$$\begin{aligned} -q \;\leq\; T \;\leq q \\ -q\ \widehat{\mathsf{se}}^{(\beta)} \leq \widehat{\beta} - \beta \leq q\ \widehat{\mathsf{se}}^{(\beta)} \end{aligned}$$

mit $q = q_{0.975}^{t_{n-2}}$. Die linke Ungleichung ergibt

$$\beta \leq \widehat{\beta} + q\ \mathsf{se}^{(\beta)}$$

analog: untere Grenze für β. – Zusammen:

$$\widehat{\beta} - q\ \widehat{\mathsf{se}}^{(\beta)} \leq \beta \leq \widehat{\beta} + q\ \widehat{\mathsf{se}}^{(\beta)}$$

$$\widehat{\beta} \pm q\ \widehat{\mathsf{se}}^{(\beta)}$$

2.3

g Vertrauensintervall für β im Beispiel:

Regression Analysis - Linear model: Y = a+bX

Dependent variable: log10(ersch) Independent variable: log10(dist)

Parameter	Estimate	Standard Error	T Value	Prob. Level
Intercept	$\widehat{\alpha} =$ 3.8996	$\mathrm{se}^{(\beta)} =$ 0.3156	$T^{(\alpha)} =$ 12.36	0
Slope	$\widehat{\beta} =$ –1.9235	$\mathrm{se}^{(\beta)} =$ 0.1783	$T^{(\beta)} = -10.79$	0

R-squared = 0.9136 $= r^2_{XY}$
Std.dev. of Error $= \widehat{\sigma}$ = 0.1145 on $n - 2 =$ 11 degrees of freedom
F-statistic: 116.4 on 1 and 11 degrees of freedom, the p-value is 3.448e-07

$$-1.9235 \pm 2.20 \cdot 0.178 = [-2.32, -1.53]$$

2.4 Vertrauens- und Prognose-Bereiche

a Wie gross ist die Erschütterung bei Distanz 50m?

Erwartungswert der Erschütterung bei 50m Distanz?

Vertrauensintervall dafür?

b Testgrösse für $h\langle x_0\rangle = y_0$:

$$T = \frac{\widehat{y}_0 - y_0}{\mathrm{se}^{(y_0)}}\,, \qquad \mathrm{se}^{(y_0)} = \widehat{\sigma}\sqrt{\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{\mathrm{SSQ}^{(X)}}}\,,$$

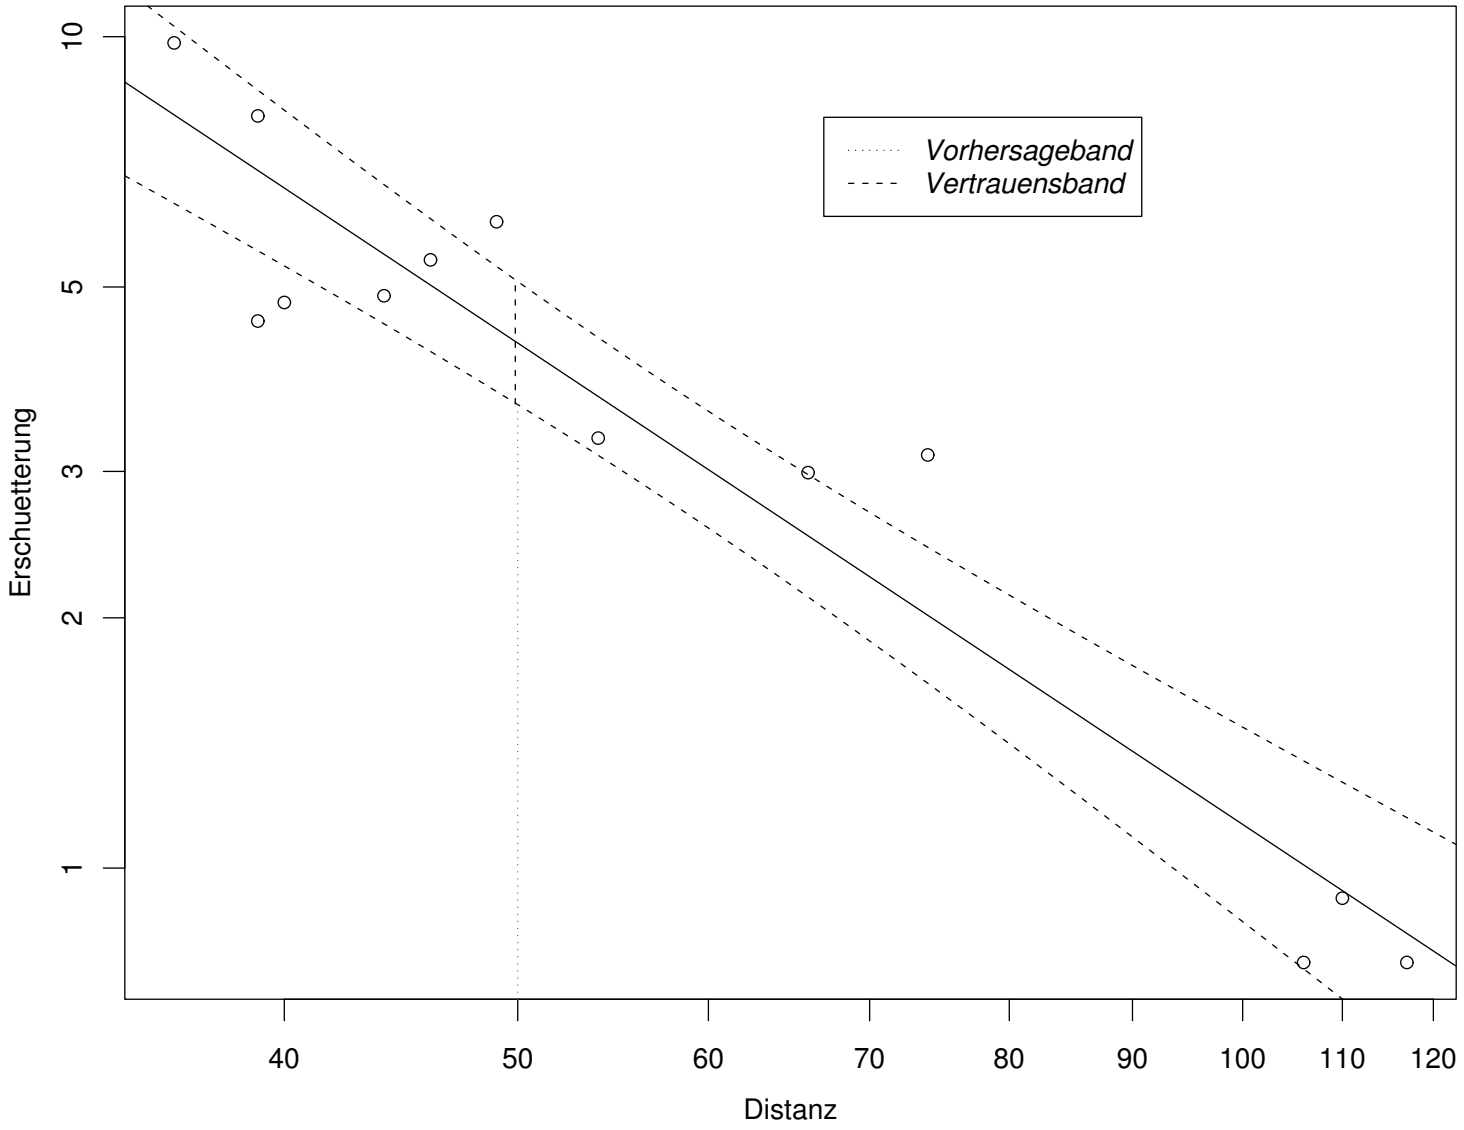
Verteilung: t-Verteilung mit $n-2$ Freiheitsgraden

Vertrauensintervall:

$$(\widehat{\alpha} + \widehat{\beta}x_0) \pm q \;\; \mathrm{se}^{(y_0)} \;.$$

2.4

c Vertrauensband



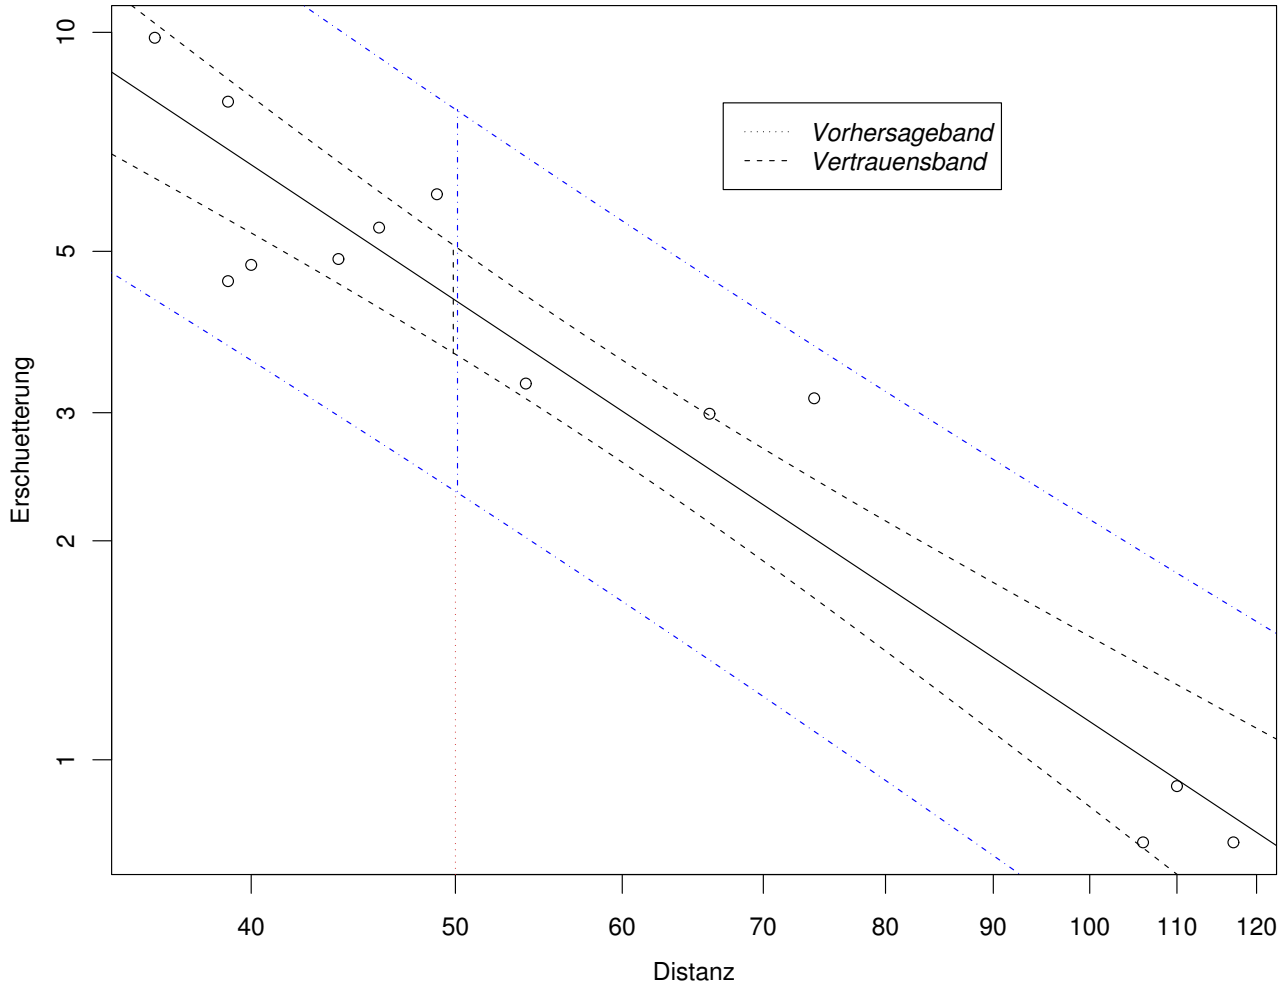
2.4

d Das „Vertrauensband" gibt an, wo die idealen Funktionswerte

$h\langle x\rangle = \mathcal{E}\langle Y\rangle$ bei gegebenen x liegen.

In welchem Bereich liegen künftige Beobachtungen (zu geg. x_0)?

... kein Vertrauensintervall, sondern ein „Vorhersage-Intervall".



2.4

e* $$\begin{aligned} R_0 &= Y_0 - (\widehat{\alpha} + \widehat{\beta} x_0) \\ &= \Big(Y_0 - (\alpha + \beta x_0)\Big) - \Big((\widehat{\alpha} + \widehat{\beta} x_0) - (\alpha + \beta x_0)\Big) \end{aligned}$$

$\Big(...\Big) - \Big(...\Big)$: beide $\sim \mathcal{N}$, unabhängig. $\longrightarrow$ $R_0 \sim \mathcal{N}\langle 0, ...\rangle$

f Interpretation nicht einfach.

$\longrightarrow$ Toleranz-Intervall.

Merkpunkte **Einfache Regression**

1. Regression ist die am meisten verbreitete Methodik der Statistik
2. Die einfache lineare Regression ist eine einfache Anwendung

   des Grundschemas:

   - Modell: $Y_i = \alpha + \beta x_i + E_i, \quad E_i \sim \mathcal{N}\langle 0, \sigma^2 \rangle$, unabhängig
   - Schätzung: Maximum likelihood führt auf Kleinste Quadrate
   - Test: Schätzung als Teststatistik, standardis. mit

     geschätzter Streuung $\longrightarrow$ t-Test
   - Vertrauensintervall: aus dem t-Test

3 Multiple lineare Regression

3.1 Modell und Statistik

a Zusammenhang zwischen einer Zielgrösse Y und
mehreren Eingangsgrössen $X^{(1)}, X^{(2)}, \ldots, X^{(m)}$

$$Y_i = \beta_0 + \beta_1 x_i^{(1)} + \beta_2 x_i^{(2)} + \ldots + \beta_m x_i^{(m)} + E_i$$

Parameter: $\beta_0, \beta_1, \beta_2, \ldots, \beta_m, \sigma^2$.

„abhängige" Variable = Zielvariable

„unabhängige" Variable = Eingangs-, erklärende Variable

b Beispiel Sprengungen: $Y = \log_{10}\langle\text{Erschütterung}\rangle$,
$X^{(1)} = \log_{10}\langle\text{Distanz}\rangle$ und $X^{(2)} = \log_{10}\langle\text{Ladung}\rangle$.

3.1

c Schätzung, Tests, Vertrauensintervalle:

Kleinste Quadrate. Theorie etwas später.

d Computer-Ergebnis

Coefficients:

	Value	Std. Error	t value	Pr(>|t|)
(Intercept)	2.8323	0.2229	12.71	0.000
log10(dist)	-1.5107	0.1111	-13.59	0.000
log10(ladung)	0.8083	0.3042	2.66	0.011

Residual standard error: 0.1529 on 45 degrees of freedom

Multiple R-Squared: 0.8048

F-statistic: 92.79 on 2 and 45 degrees of freedom

p-value 1.11e-16

3.1

e Tests: Welche Fragen sind zu stellen?

Frage **A.**

Beeinflusst die Gesamtheit der Eingangsgrössen die Zielgrösse?

$\longrightarrow$ „F-Test"

Coefficients:

...

Residual standard error: 0.1529 on 45 degrees of freedom

Multiple R-Squared: 0.8048

F-statistic: 92.79 on 2 and 45 degrees of freedom

p-value 1.11e-16

f Varianzanalyse-Tabelle

Analysis of variance

		Df	Sum of Sq	Mean Sq	F Value	Pr(F)
Regression	$m =$	2	$\text{SSQ}^{(R)} =$ 136.772	68.386	$T =$ 82.43	0.0000
Residuals	$n - p =$	120	$\text{SSQ}^{(E)} =$ 99.554	$\widehat{\sigma}^2 =$ 0.830		*P-Wert*
Total		122	$\text{SSQ}^{(Y)} =$ 236.326			

3.1

g Coefficients:

...

Residual standard error: 0.1529 on 45 degrees of freedom

Multiple R-Squared: 0.8048

F-statistic: 92.79 on 2 and 45 degrees of freedom

p-value 1.11e-16

„Multiple R-Squared" ist das Quadrat der

multiplen Korrelation = corr(Y_i, angepasste Werte $\widehat{y}_i$)

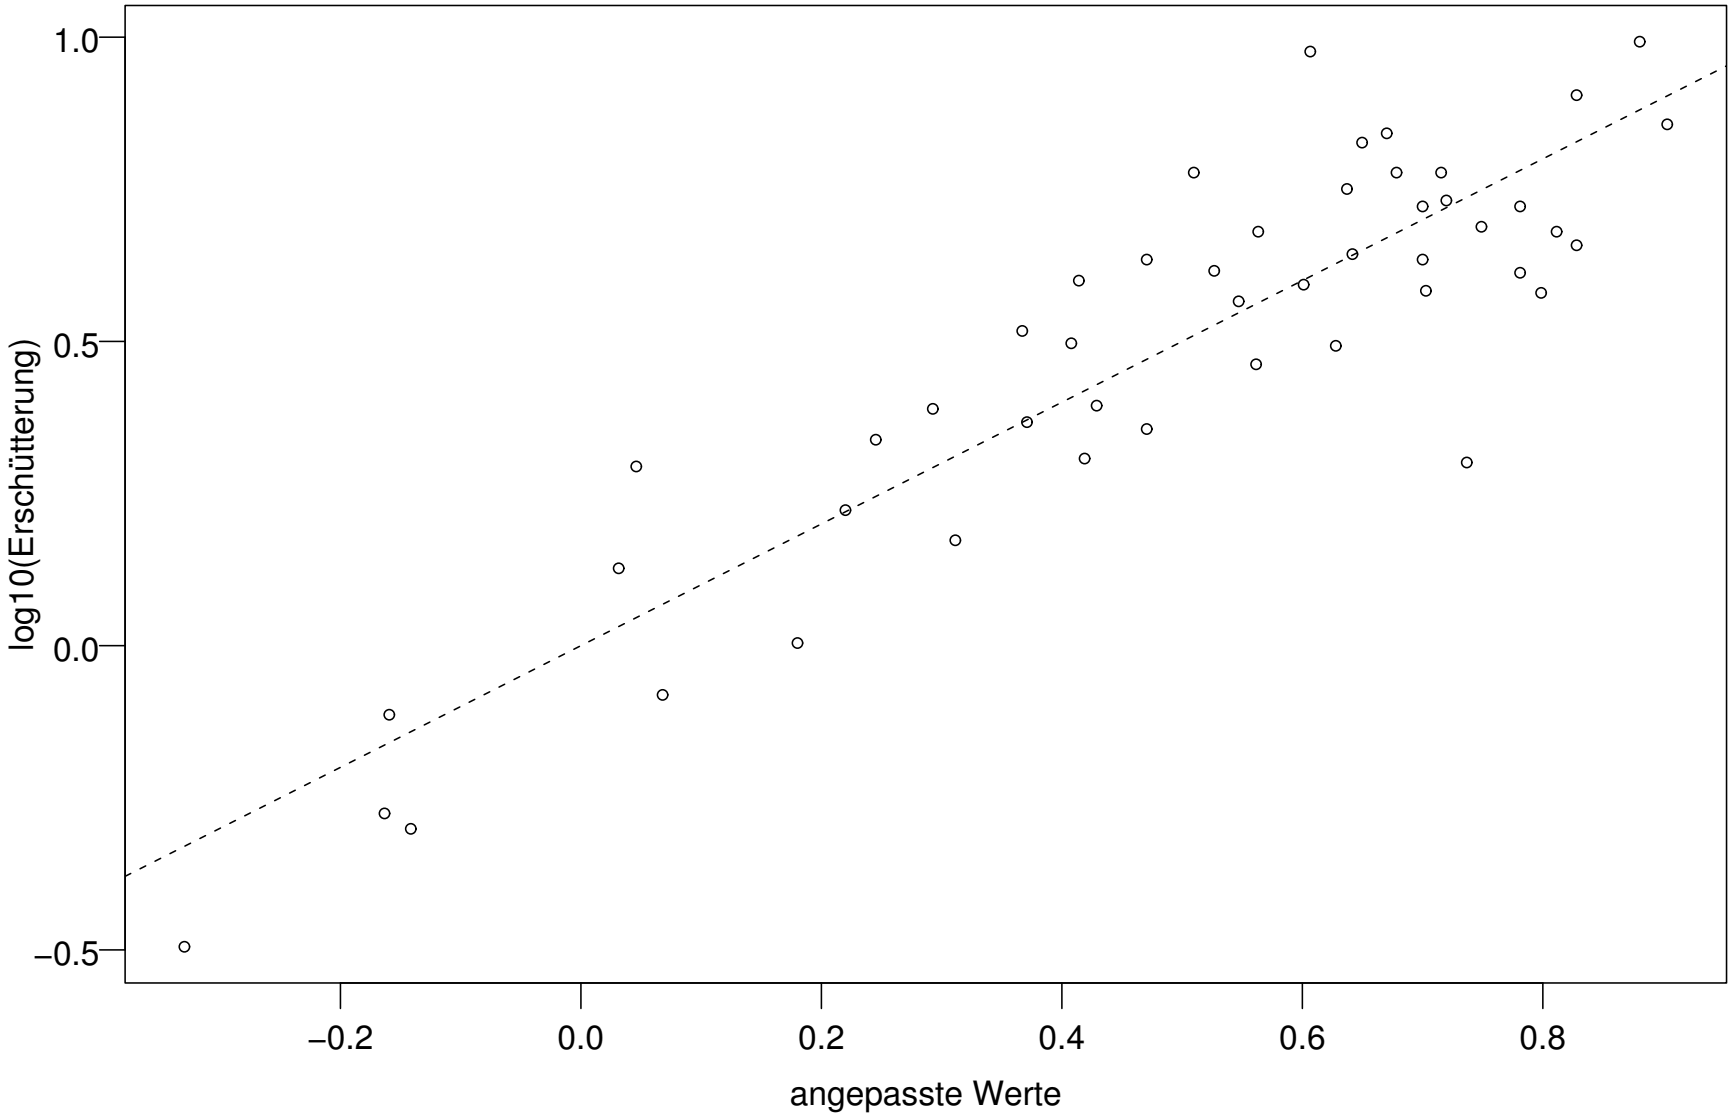
$$\widehat{y}_i = \widehat{\beta}_0 + \widehat{\beta}_1 x_i^{(1)} + \widehat{\beta}_2 x_i^{(2)} + \ldots + \widehat{\beta}_m x_i^{(m)}$$

$R^2 =$ Bestimmtheitsmass,

misst den Anteil der erklärten Streuung

an der Streuung der Y-Werte,

$R^2 = 1 - \text{SSQ}^{(E)}/\text{SSQ}^{(Y)}$.


1.0
0.5
0.0
−0.5
log10(Erschütterung)
−0.2
0.0
0.2
0.4
0.6
0.8
angepasste Werte

3.1

h Frage **B.**

Einfluss der einzelnen Variablen $X^{(j)}$?

Coefficients:

	Value	Std. Error	t value	$Pr(>\|t\|)$
(Intercept)	2.8323	0.2229	12.71	0.000
log10(dist)	-1.5107	0.1111	-13.59	0.000
log10(ladung)	0.8083	0.3042	2.66	0.011

Residual standard error: 0.1529 on 45 degrees of freedom
Multiple R-Squared: 0.8048
F-statistic: 92.79 on 2 and 45 degrees of freedom
p-value 1.11e-16

Der t-Wert und der P-Wert in derjenigen Zeile, die $X^{(j)}$ entspricht,

prüft, ob die Variable $X^{(j)}$ aus dem Modell weggelassen werden kann:

Nullhypothese $\beta_j = 0$.

3.1

i Vertrauensintervall für β_j: $\widehat{\beta}_j \pm t_{n-p}^{(0.975)} \, \mathrm{se}^{(\beta_j)}$

Coefficients:

	Value	Std. Error	t value	Pr(>|t|)
(Intercept)	2.8323	0.2229	12.71	0.000
log10(dist)	-1.5107	0.1111	-13.59	0.000
log10(ladung)	0.8083	0.3042	2.66	0.011

Residual standard error: 0.1529 on 45 degrees of freedom
Multiple R-Squared: 0.8048
F-statistic: 92.79 on 2 and 45 degrees of freedom
p-value 1.11e-16

j Beispiel: $-1.5107 \pm 2.014 \cdot 0.1111$

$= -1.5107 \pm 0.2237 = [1.2869, 1.7345]$.

3.1

k “Significance”: Kolonne `t` in üblichen Tabellen: Überflüssig!?

Mass für Signifikanz, anders als P-Wert

$$\widetilde{T}_j = \frac{\widehat{\beta}_j}{\mathsf{se}^{(\beta_j)} \cdot q_{0.975}^{(t_k)}} = T_j / q_{0.975}^{(t_k)} \cdot$$

$|\widetilde{T}_j| > 1$ bedeutet signifikanter Koeffizient

Coefficients:

	coef	stcoef	signif	R2.x	df	p.value
(Intercept)	2.832	0.000	6.31	NA	1	0.000
log10(dist)	-1.511	-0.903	-6.75	0.01659	1	0.000
log10(ladung)	0.808	0.176	1.32	0.01659	1	0.011

St.dev. of Error = 0.1529 on 45 degrees of freedom

Multiple R-Squared: 0.8048

F-statistic: 92.79 on 2 and 45 degrees of freedom

p-value 1.11e-16

Vertrauensintervall: Bis auf Faktor $\widetilde{T}_j \pm 1$.

$$\frac{\widehat{\beta}_j}{\widetilde{T}_j} \cdot (\widetilde{T}_j \pm 1) = \widehat{\beta}_j \cdot (1 \pm 1/\widetilde{T}_j) \ .$$

l Standardisierte Koeffizienten.

$$\widehat{\beta}^*_j = \widehat{\beta}_j \cdot \mathrm{sd}\left\langle X^{(j)} \right\rangle / \mathrm{sd}\left\langle Y \right\rangle \ .$$

Einfache Regression: $\widehat{\beta}^*_j =$ Korrelation.

Allg: Um wie viel verändert sich Y, gemessen in $\mathrm{sd}\left\langle Y \right\rangle$-Einh.,

wenn sich $X^{(j)}$ um eine $\mathrm{sd}\left\langle X^{(j)} \right\rangle$ verändert?

$\longrightarrow$ Vergleiche der Einflussstärke von versch. Eingangsgrössen.

3.1

m Kollinearitätsmass. `R2.x` Bestimmtheitsmass für Regression von $X^{(j)}$ als Zielgrösse auf alle anderen Regressoren.

Soll niedrig sein, sonst sind Koeffizienten schlecht bestimmt.

Siehe später.

3.2 Vielfalt der Fragestellungen

a Im Modell der multiplen Regression werden

keine Annahmen über die X-Variablen gemacht. Beliebig:

- Datentyp: stetig, diskret, zweiwertig,

  später nominal.

- Verteilung der einzelnen Variablen: keine. Nicht zufällig.

- Gemeinsame Verteilung der Variablen: keine. Nicht zufällig.

  Keine Unabhängigkeit vorausgesetzt!

  Ein $X^{(j)}$ darf eine deterministische (nicht-lineare) Funktion einer anderen oder mehrerer anderer sein.

3.2

c Binäre Eingangs-Variable, $Y_i = \beta_0 + \beta_1 x_i + E_i$

$\longrightarrow Y_i = \beta_0 + E_i$ für $x_i = 0$,

$Y_i = \beta_0 + \beta_1 + E_i$ für $x_i = 1$.

$\beta_0 = \mu_0 =$ Erwartungswert für Gr. $x_i = 0$,

$\beta_0 + \beta_1 = \mu_1 =$ Erwartungswert für Gr. $x_i = 1$.

$\longrightarrow$ Zwei-Gruppen-Problem = Spezialfall der (einfachen) Regression.

3.2

d Beispiel Sprengungen: Betrachte nur 2 Messstellen.

$$Y_i = \beta_0 + \beta_1 x_i^{(1)} + \beta_2 x_i^{(2)} + E_i \ ,$$

$X^{(1)} = 0$ für eine Messst., $= 1$ für andere; $X^{(2)}$: log Distanz.

$\longrightarrow$ Zwei Geraden $y = \beta_0 + \beta_2 x^{(2)}$, $y = (\beta_0 + \beta_1) + \beta_2 x^{(2)}$

Gleiche Steigung β_1, Geraden sind parallel.

3.2

e 4 Messstellen $\longrightarrow$ Indikatorvariable für Gruppen j:

$$x_i^{(j)} = \begin{cases} 1 & \text{falls } i\text{-te Beobachtung aus der } j\text{-ten Gruppe} \\ 0 & \text{sonst} \end{cases} .$$

Modell:

$$Y_i = \mu_1 x_i^{(1)} + \mu_2 x_i^{(2)} + \ldots + E_i$$

Setzt man $\mu_j = \beta_j$, so steht das multiple Regressionsmodell da,

allerdings ohne Achsenabschnitt β_0.

Nominale Eingangs-Var., ℓ Werte $\longrightarrow$ verwandeln in ℓ dummy variables.

3.2

f Modell mit Achsenabschnitt: Parameter nicht eindeutig. Lösung:

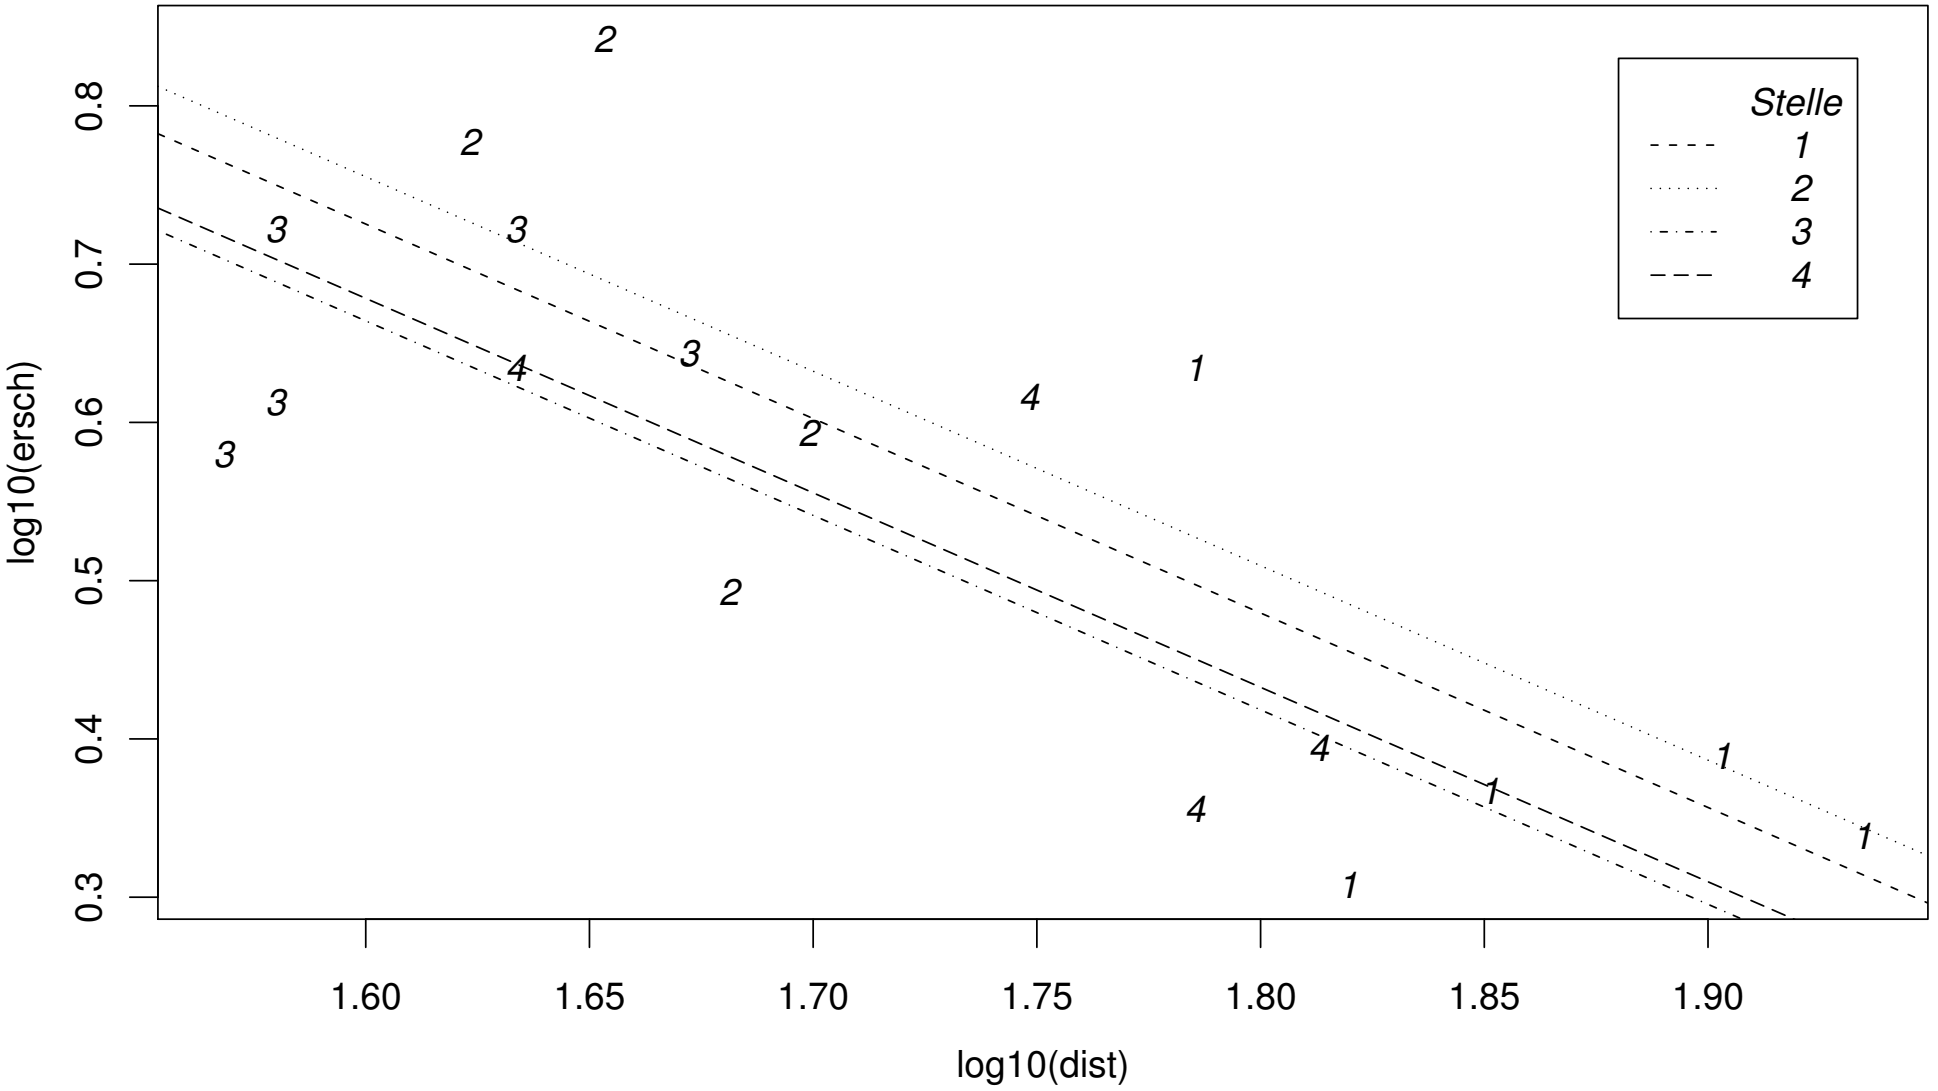
– eine „Nebenbedingung" einführen oder

– eine Variable weglassen.

g Coefficients:

	Value	Std. Error	t value	Pr(>|t|)	Signif
(Intercept)	2.51044	0.28215	8.90	0.000	***
log10(dist)	-1.33779	0.14073	-9.51	0.000	***
log10(ladung)	0.69179	0.29666	2.33	0.025	*
St2	0.16430	0.07494	2.19	0.034	*
St3	0.02170	0.06366	0.34	0.735	
St4	0.11080	0.07477	1.48	0.146	

Residual standard error: 0.1468 on 42 degrees of freedom
Multiple R-Squared: 0.8322
F-statistic: 41.66 on 5 and 42 degrees of freedom, p-value 3.22e-15


Stelle
1
2
3
4
log10(ersch)
0.3
0.4
0.5
0.6
0.7
0.8
log10(dist)
1.60
1.65
1.70
1.75
1.80
1.85
1.90

3.2

h* Notation, Programm-Eingabe:

`log10(ersch) ~ log10(dist) + log10(ladung) + St`

j Frage **C:**

Unterscheiden sich die Stellen überhaupt

in bezug auf die Zielgrösse?

Nullhypothese: Die Koeffizienten der Variablen `St2` bis `St4` sind alle =0.

k F-Test zum Vergleich von Modellen

l

	Df	Sum of Sq	RSS	F Value	Pr(F)
log10(dist)	1	1.947	2.851	90.4	4.9e-12
log10(ladung)	1	0.117	1.022	5.44	0.025
St	3	0.148	1.052	2.283	0.093

Funktion regr

```
Call:
regr(formula = log10(ersch) ~ log10(dist) + log10(ladung) + St,
    data = dd)
Fitting function:  lm

Terms:
                coef stcoef signif  R2.x df p.value
(Intercept)    2.510     NA  4.409    NA  1      NA
log10(dist)   -1.338 -0.799 -4.711 0.435  1   0.000
log10(ladung)  0.692  0.151  1.156 0.048  1   0.025
St                NA     NA  0.899 0.170  3   0.093

Coefficients for factors:
$St
     1      2      3      4
0.0000 0.1643 0.0217 0.1108

St.dev.error:  0.147   on 42 degrees of freedom
Multiple R^2:  0.832    Adjusted R-squared: 0.812
F-statistic:   41.7   on 5 and 42 d.f.,  p.value: 3.22e-15
```

3.2

o Einfluss der Stelle: Je eine additive Konstante für jede Stelle.

Verschiedene Steigungen für verschiedene Stellen?

$\longrightarrow$ Wechselwirkungen.

p Einfacher Fall: Zwei Geraden mit verschiedener Steigung

$$Y_i = \beta_0 + \beta_2 x_i^{(2)} + \Delta\beta_0 x_i^{(1)} + \Delta\beta_2 x_i^{(1)}\ x_i^{(2)} + E_i$$

$x_i^{(1)}$: Gruppenzugehörigkeit

Multiple Regression? $\longrightarrow x^{(1)}\ x_i^{(2)} = x_i^{(3)}$

$$\Delta\beta_0 = \beta_1\ ;\quad \Delta\beta_2 = \beta_3$$

“Keine Wechselwirkung” = Geraden parallel = $\Delta\beta_2 = \beta_3 = 0$

$\longrightarrow$ Test: t-Test für $\beta_3 = 0$.

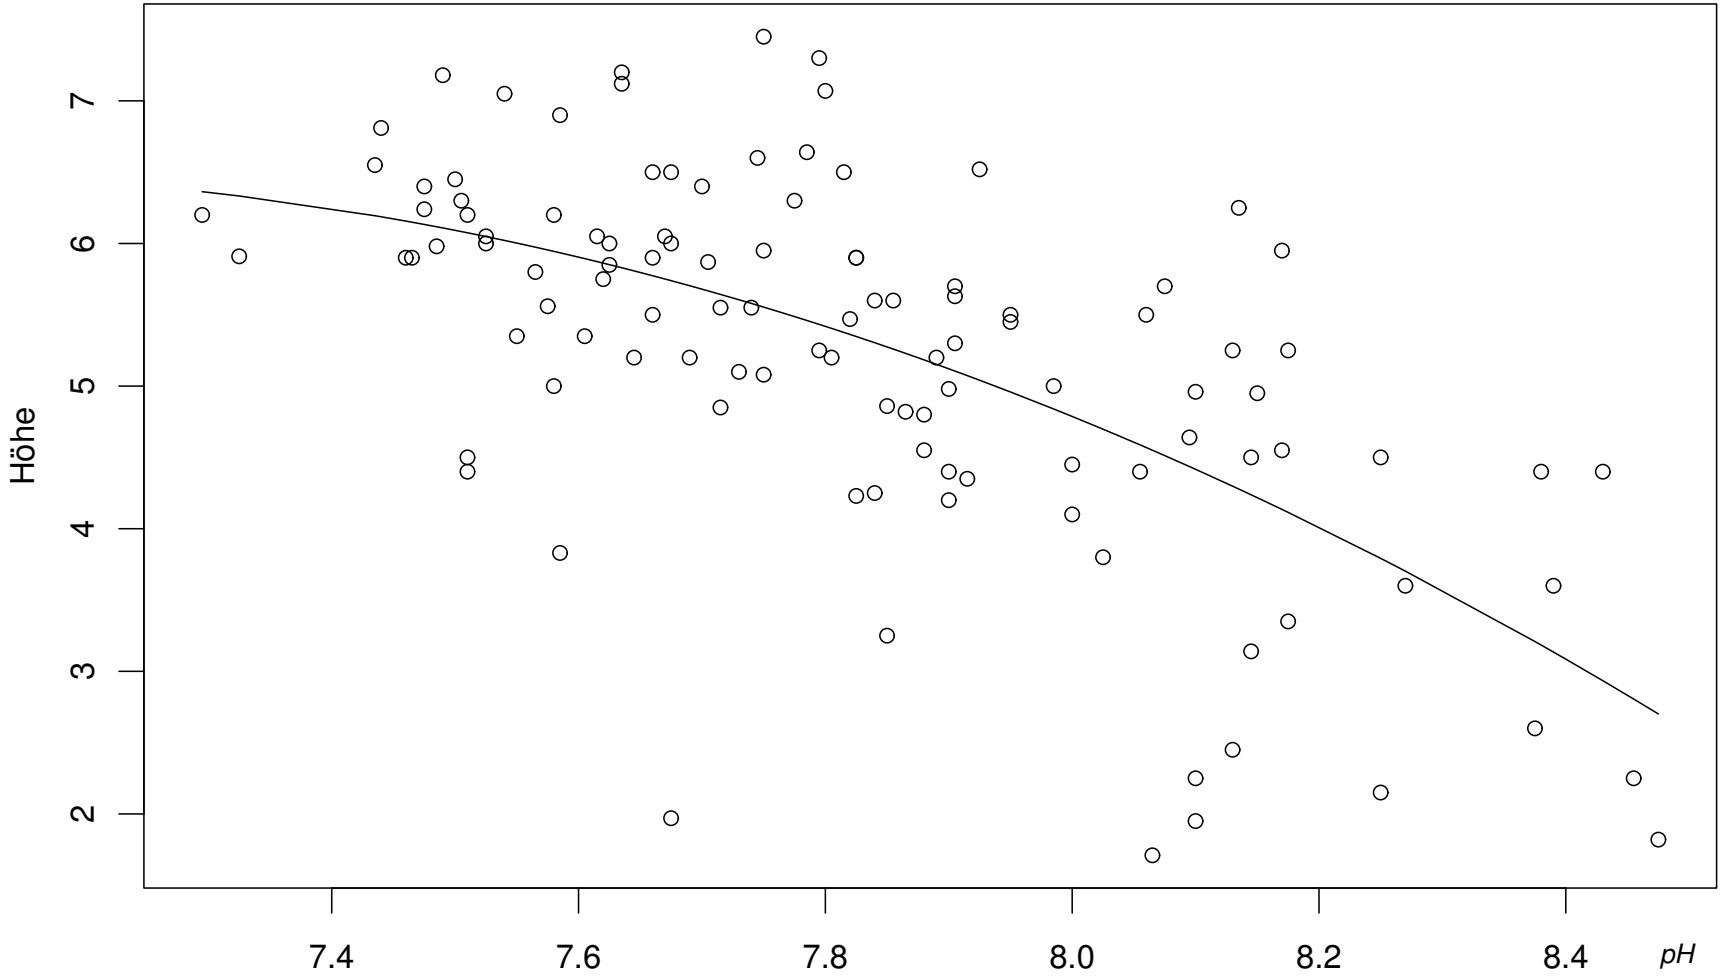
“Kein Einfluss der Gruppierung”: $\beta_1 = 0$ und $\beta_3 = 0$ $\longrightarrow$ F-Test.

3.2

q Quadratischer Zusammenhang:

$$Y_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + E_i \ .$$

$X^{(2)} = (X^{(1)})^2 \longrightarrow$ quadratische Regression.



3.2

r quadratische $\longrightarrow$ polynomiale Regression.

Spezialfall der multiplen linearen Regression!

Linear in den Koeffizienten!

$$\beta_0 + \beta_1 x_i^{(1)} + \beta_2 x_i^{(2)} + \ldots + \beta_m x_i^{(m)}$$

s Optimum der Zielgrösse? $\longrightarrow$ nicht monotone Regressionsfunktion

Einfachste Fn: Quadratisch.

2 Eingangs-Variable: Quardatische Fläche:

$$Y = \beta_0 + \beta_1 x^{(1)} + \beta_2 x^{(2)} + \beta_{11} x^{(1)2} + \beta_{22} x^{(2)2} + \beta_{12} x^{(1)} x^{(2)}$$

βs schätzen, Optimum bestimmen!

3.2

t Das Modell der multiplen linearen Regression

ist sehr flexibel:

- Transformation der X - (und Y -) Variablen:

  Linearisieren des Zusammenhangs.

- Vergleich von zwei Gruppen.

- Zwei Geraden. „Wechselwirkungen".

- Mehrere Gruppen, nominale Eingangs-Variable.

  Vgl. Varianzanalyse.

- Polynomiale Regression.

3.3

a Einfluss mehrerer Eingangsgrössen auf die Zielgrösse

- Multiple Regression
- Mehrere einfache Regressionen: einfacher zu verstehen!

3.3 Ist multiple Regression mehr als die Zusammenfassung von einfachen R.?

b Modifiziertes Beispiel der Sprengungen.

Beschränkung auf Stellen 3 und 6, Distanz $<$ 100 m, -1 Ausreisser

```
--- Distanz ----------------------------------------------
lm(formula = log10(ersch) ~ log10(dist), data = d.sprmod)
Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept)    0.8976     0.5736   1.565    0.127
log10(dist)   -0.1316     0.3260  -0.404    0.689

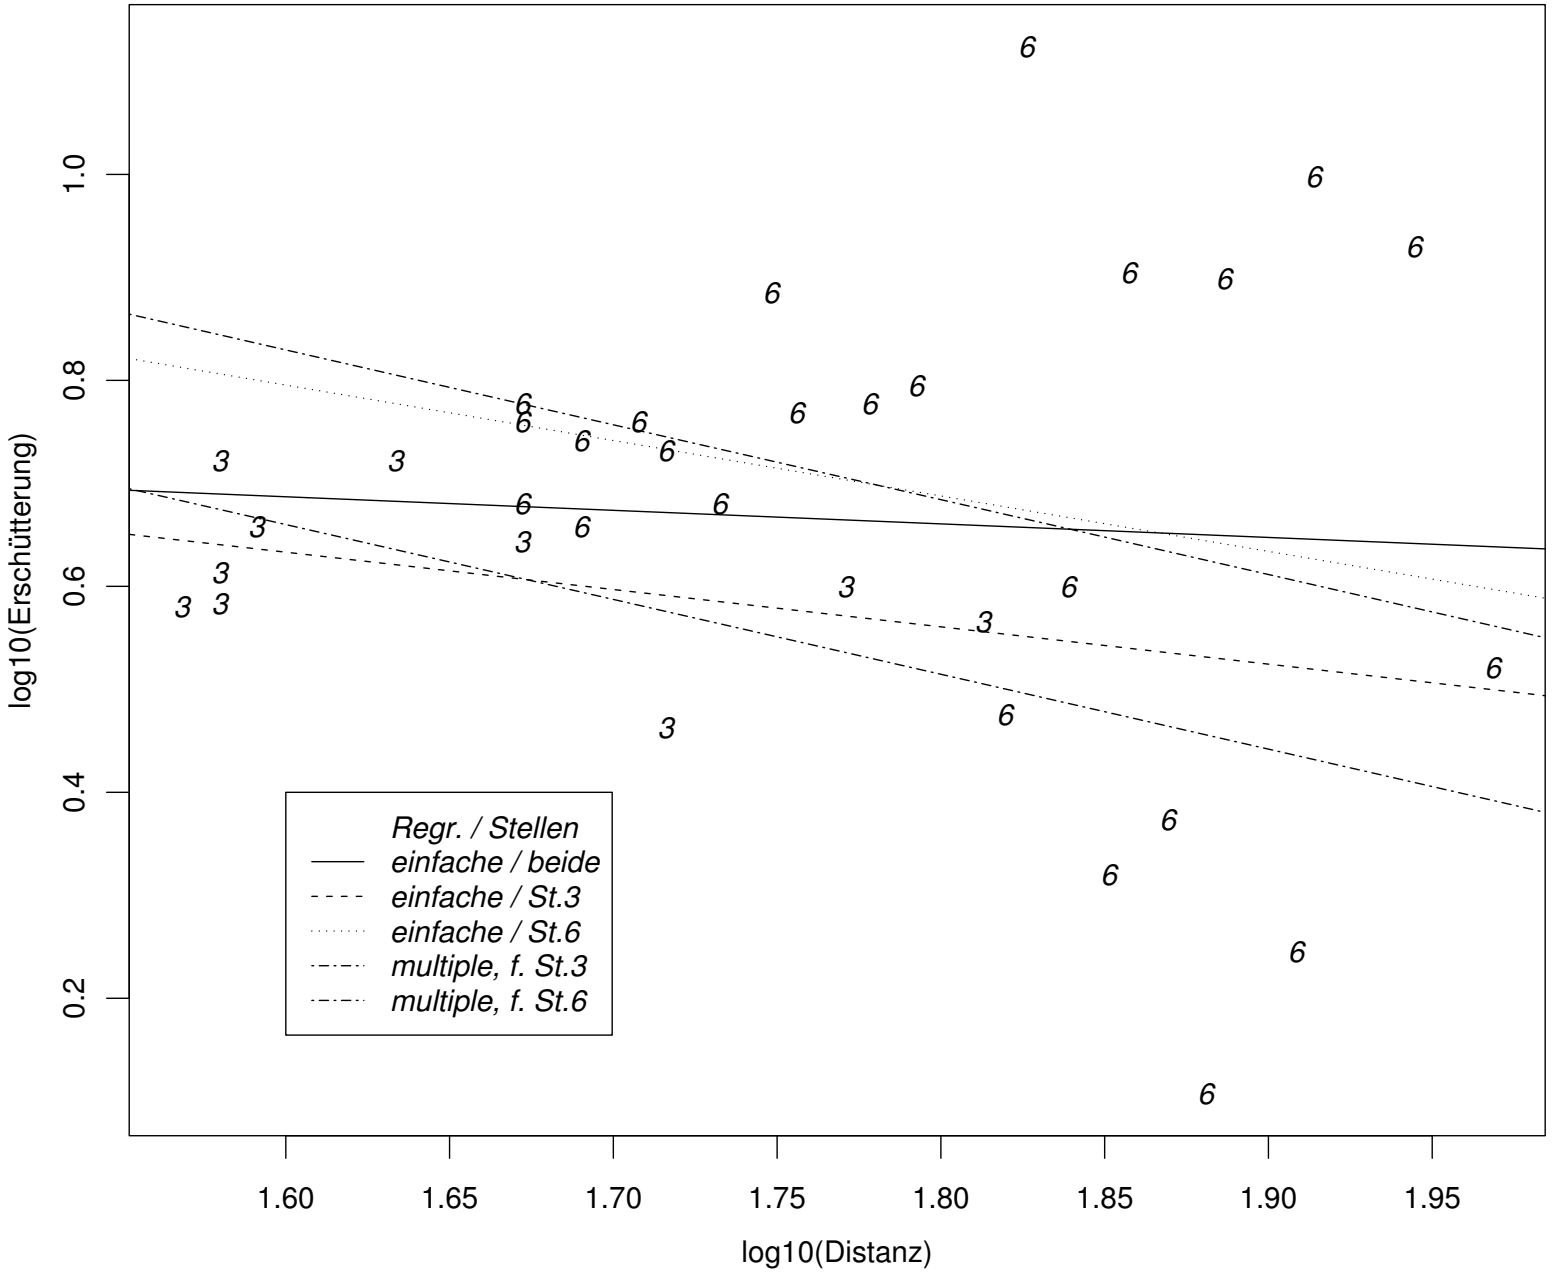
Residual standard error: 0.2134 on 32 degrees of freedom
Multiple R-Squared: 0.00507, Adjusted R-squared: -0.02602
F-statistic: 0.1631 on 1 and 32 DF,  p-value: 0.689
--- Ladung -----------------------------------------------
lm(formula = log10(ersch) ~ log10(ladung), data = d.sprmod)
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)     0.1026     0.1938   0.530  0.60011
log10(ladung)   1.3359     0.4525   2.952  0.00587 **

Residual standard error: 0.1896 on 32 degrees of freedom
Multiple R-Squared: 0.2141,     Adjusted R-squared: 0.1895
F-statistic: 8.715 on 1 and 32 DF,  p-value: 0.005867
----------------------------------------------------------
```

```
--- Distanz und Ladung ---------------------------------
lm(formula = log10(ersch) ~ log10(dist) + log10(ladung)
   + stelle, data = d.sprmod, na.action = na.omit)
Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept)     1.193      0.582    2.05   0.0491 *
log10(dist)    -0.727      0.355   -2.05   0.0495 *
log10(ladung)   1.493      0.442    3.38   0.0020 **
stelle          0.170      0.086    1.97   0.0580 .

Residual standard error: 0.181 on 30 degrees of freedom
Multiple R-Squared: 0.327,      Adjusted R-squared: 0.26
F-statistic: 4.86 on 3 and 30 DF,  p-value: 0.00717
--------------------------------------------------------
```

Wir erwarten $\beta_{\text{dist}} < -1$, $\beta_{\text{lad}} = 1$.


log10(Erschütterung)
1.0
0.8
0.6
0.4
0.2
1.60
1.65
1.70
1.75
1.80
1.85
1.90
1.95
log10(Distanz)
Regr. / Stellen
einfache / beide
einfache / St.3
einfache / St.6
multiple, f. St.3
multiple, f. St.6

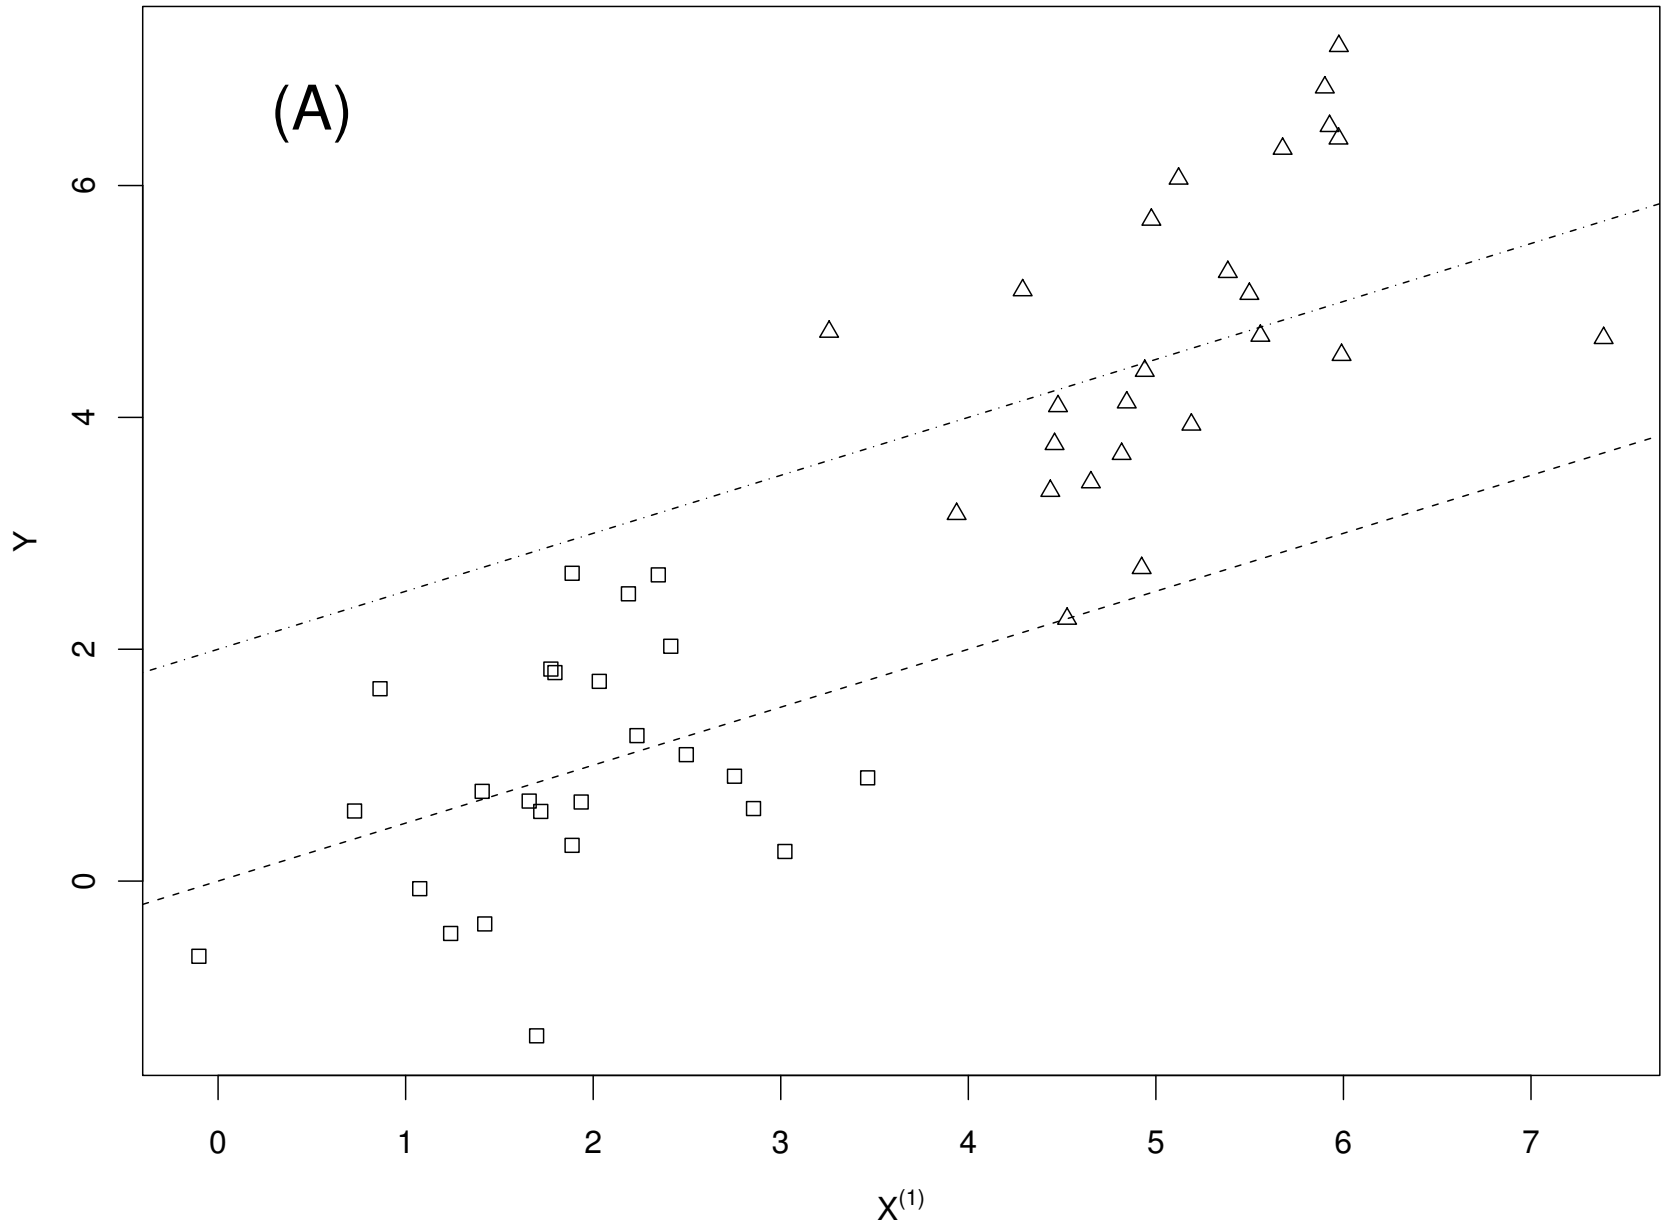
3.3

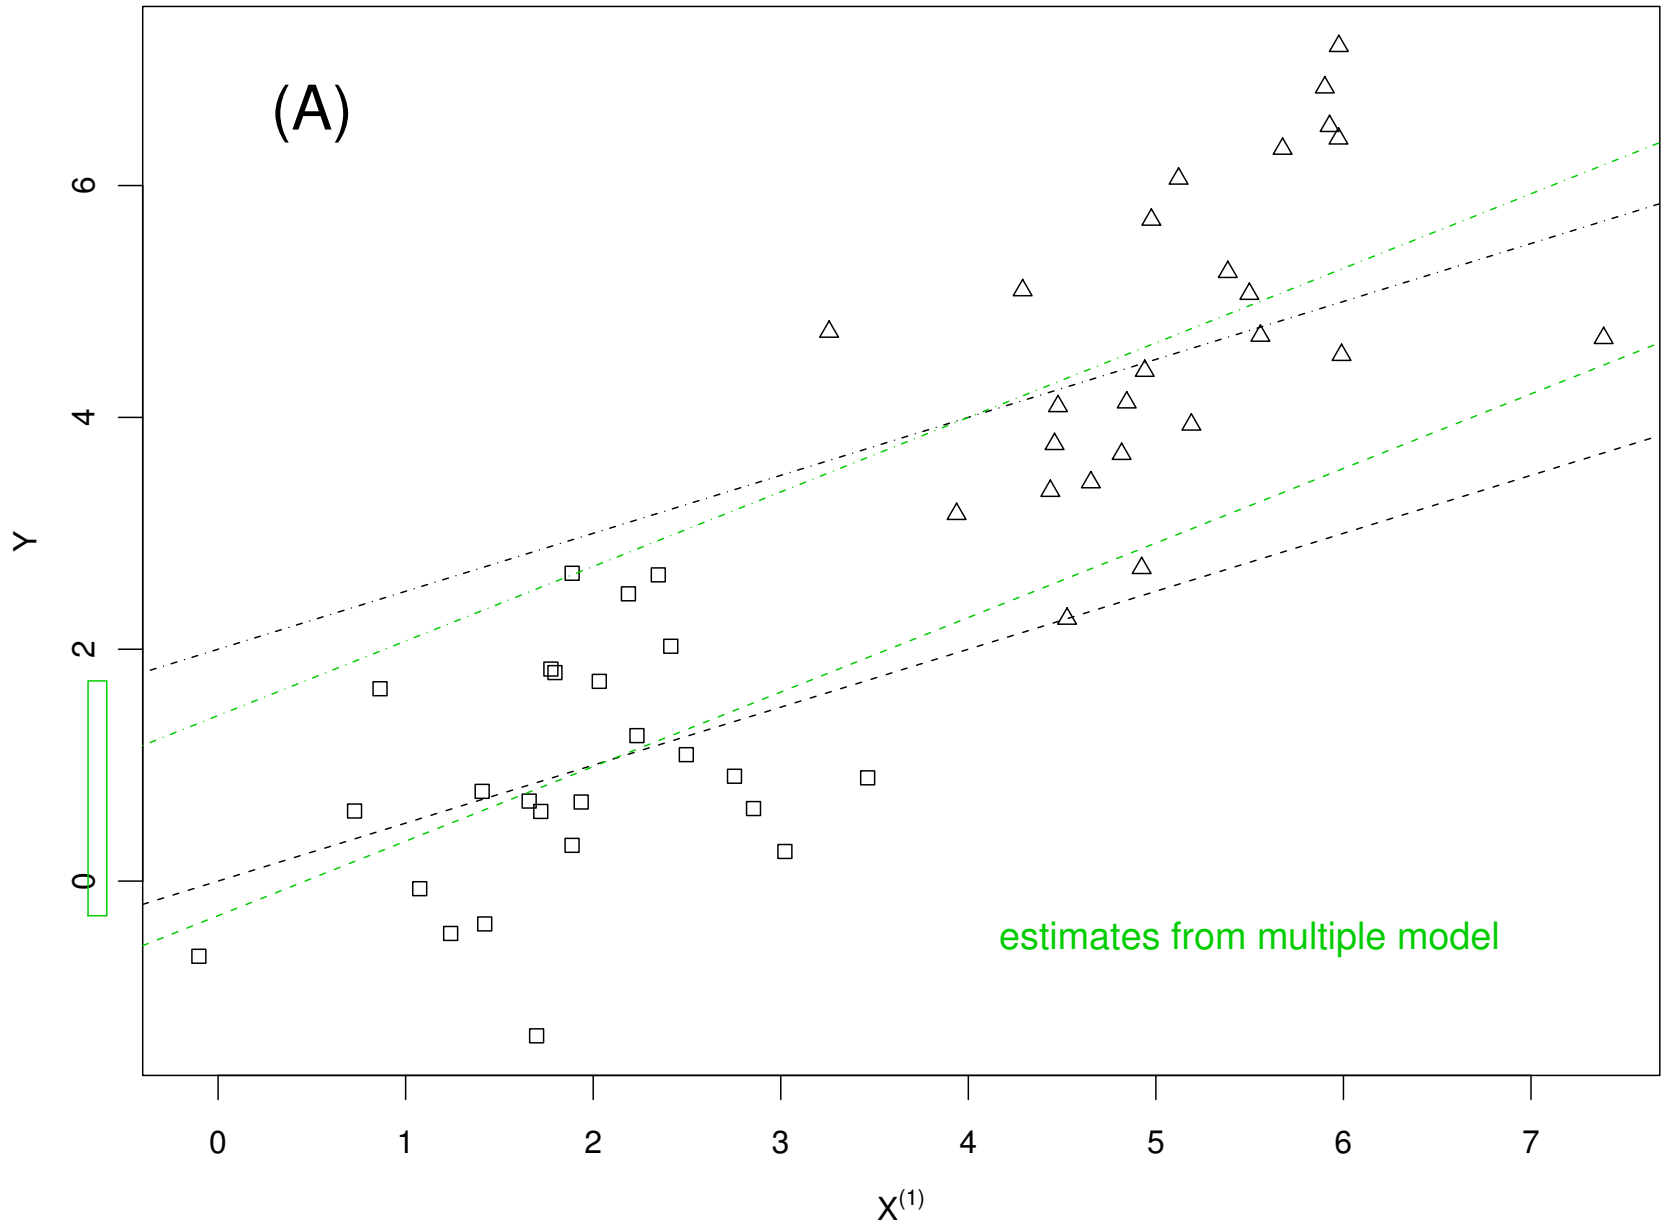
c Interpretation:

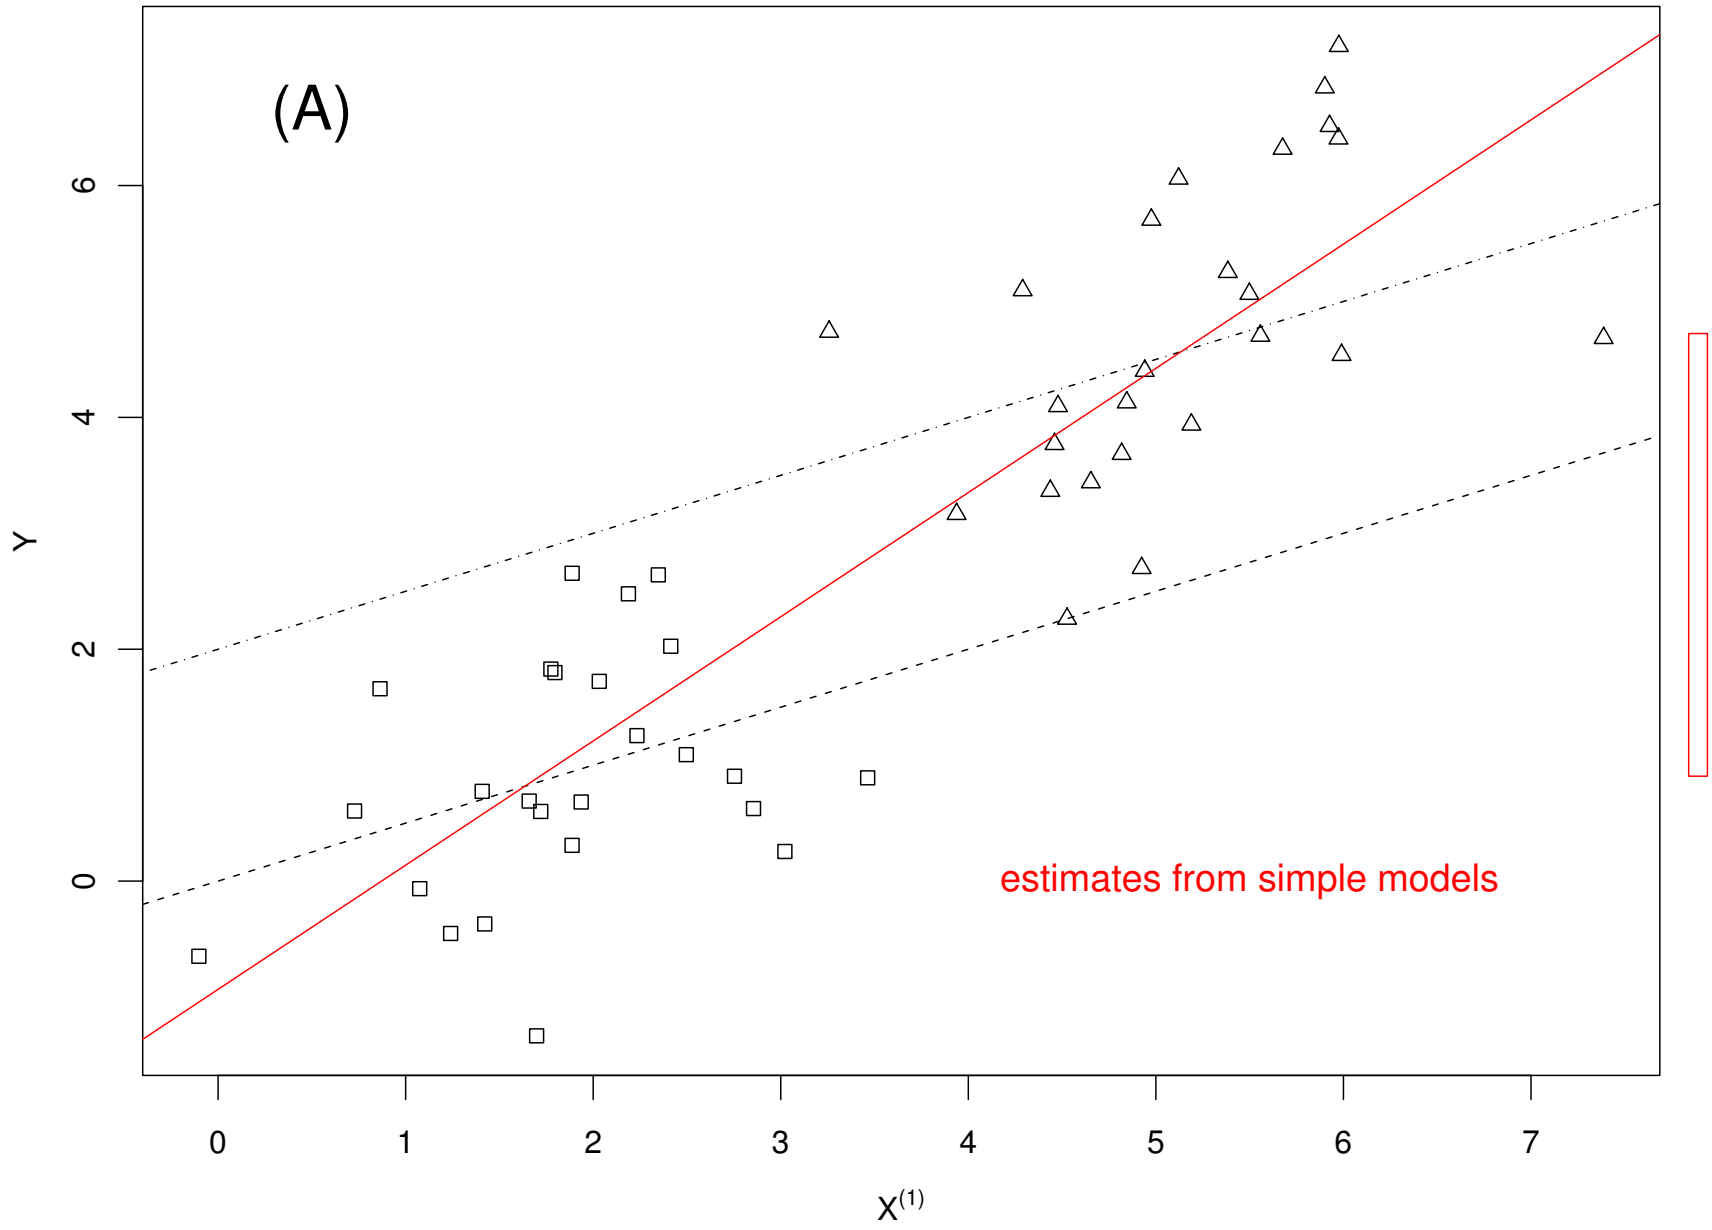
Höhere Distanz $\leftrightarrow$ andere Stelle, höhere Ladung

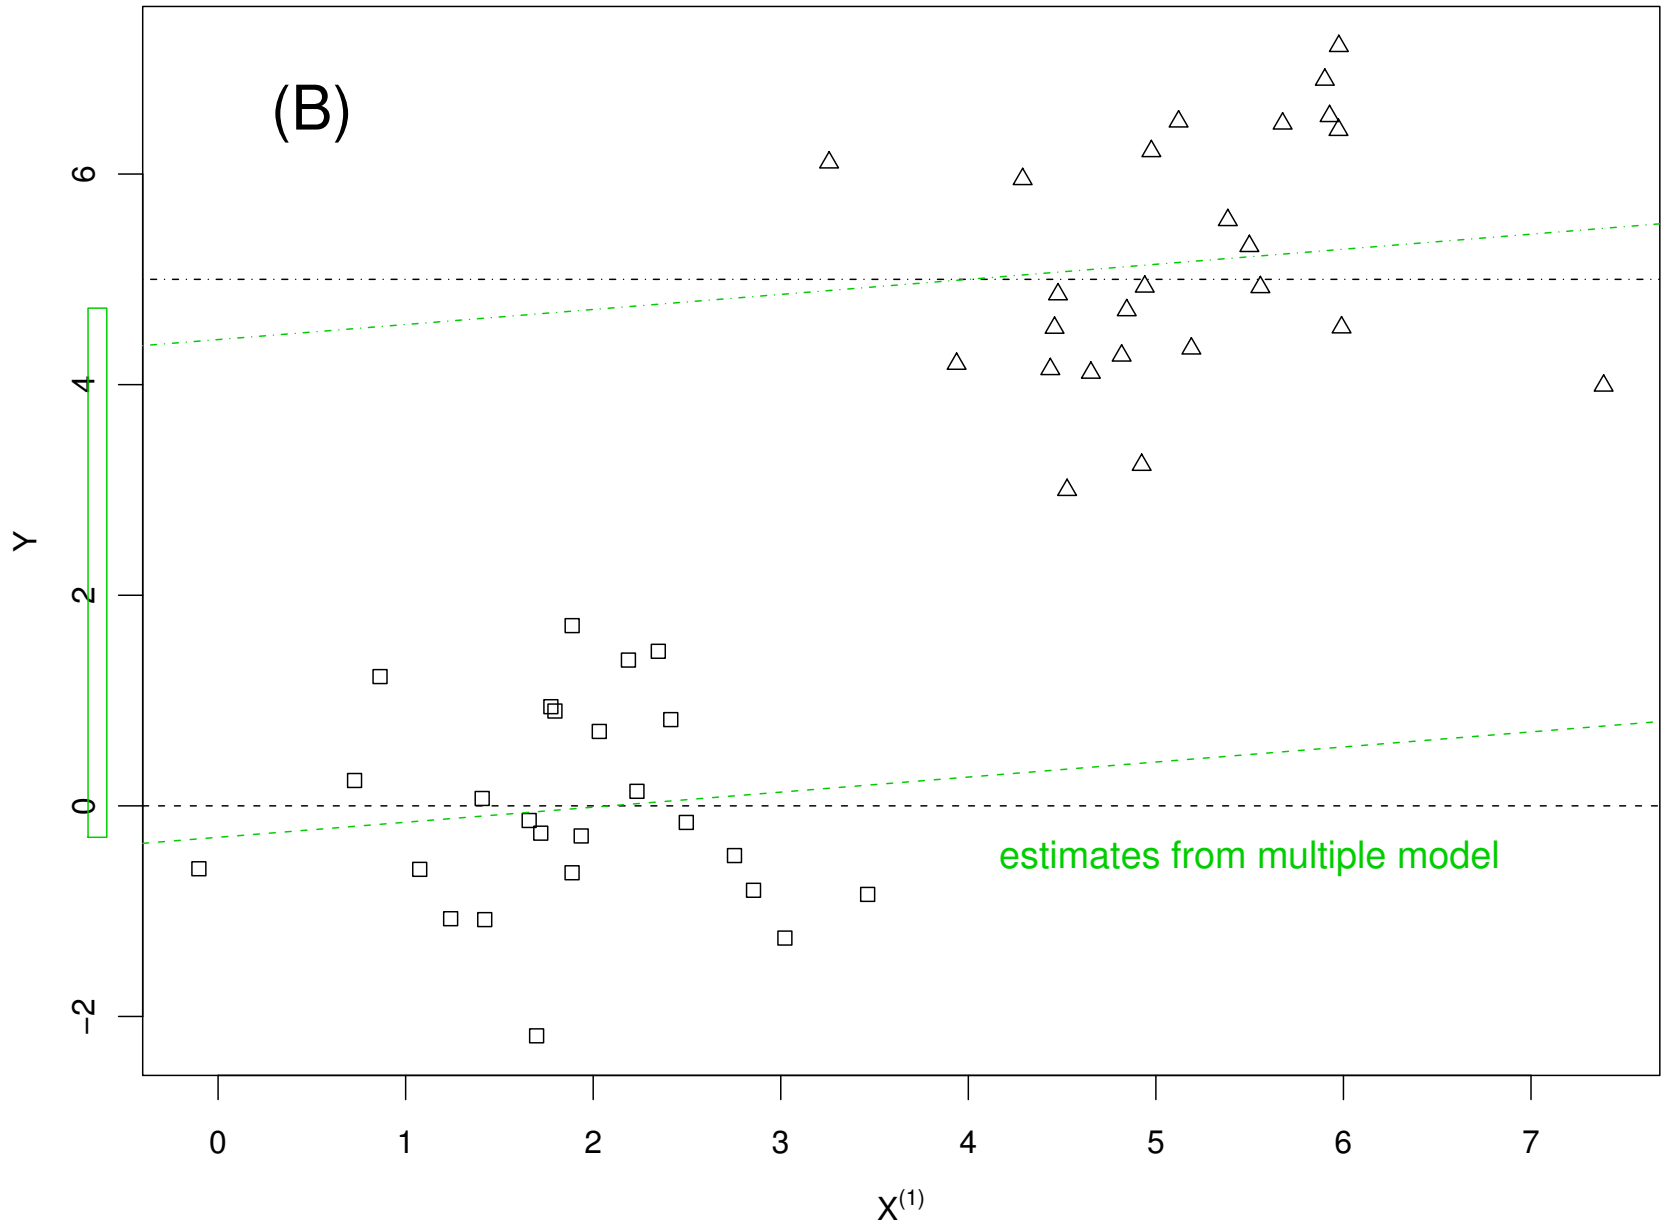
$\longrightarrow$ etwa gleiche Erschütterung.

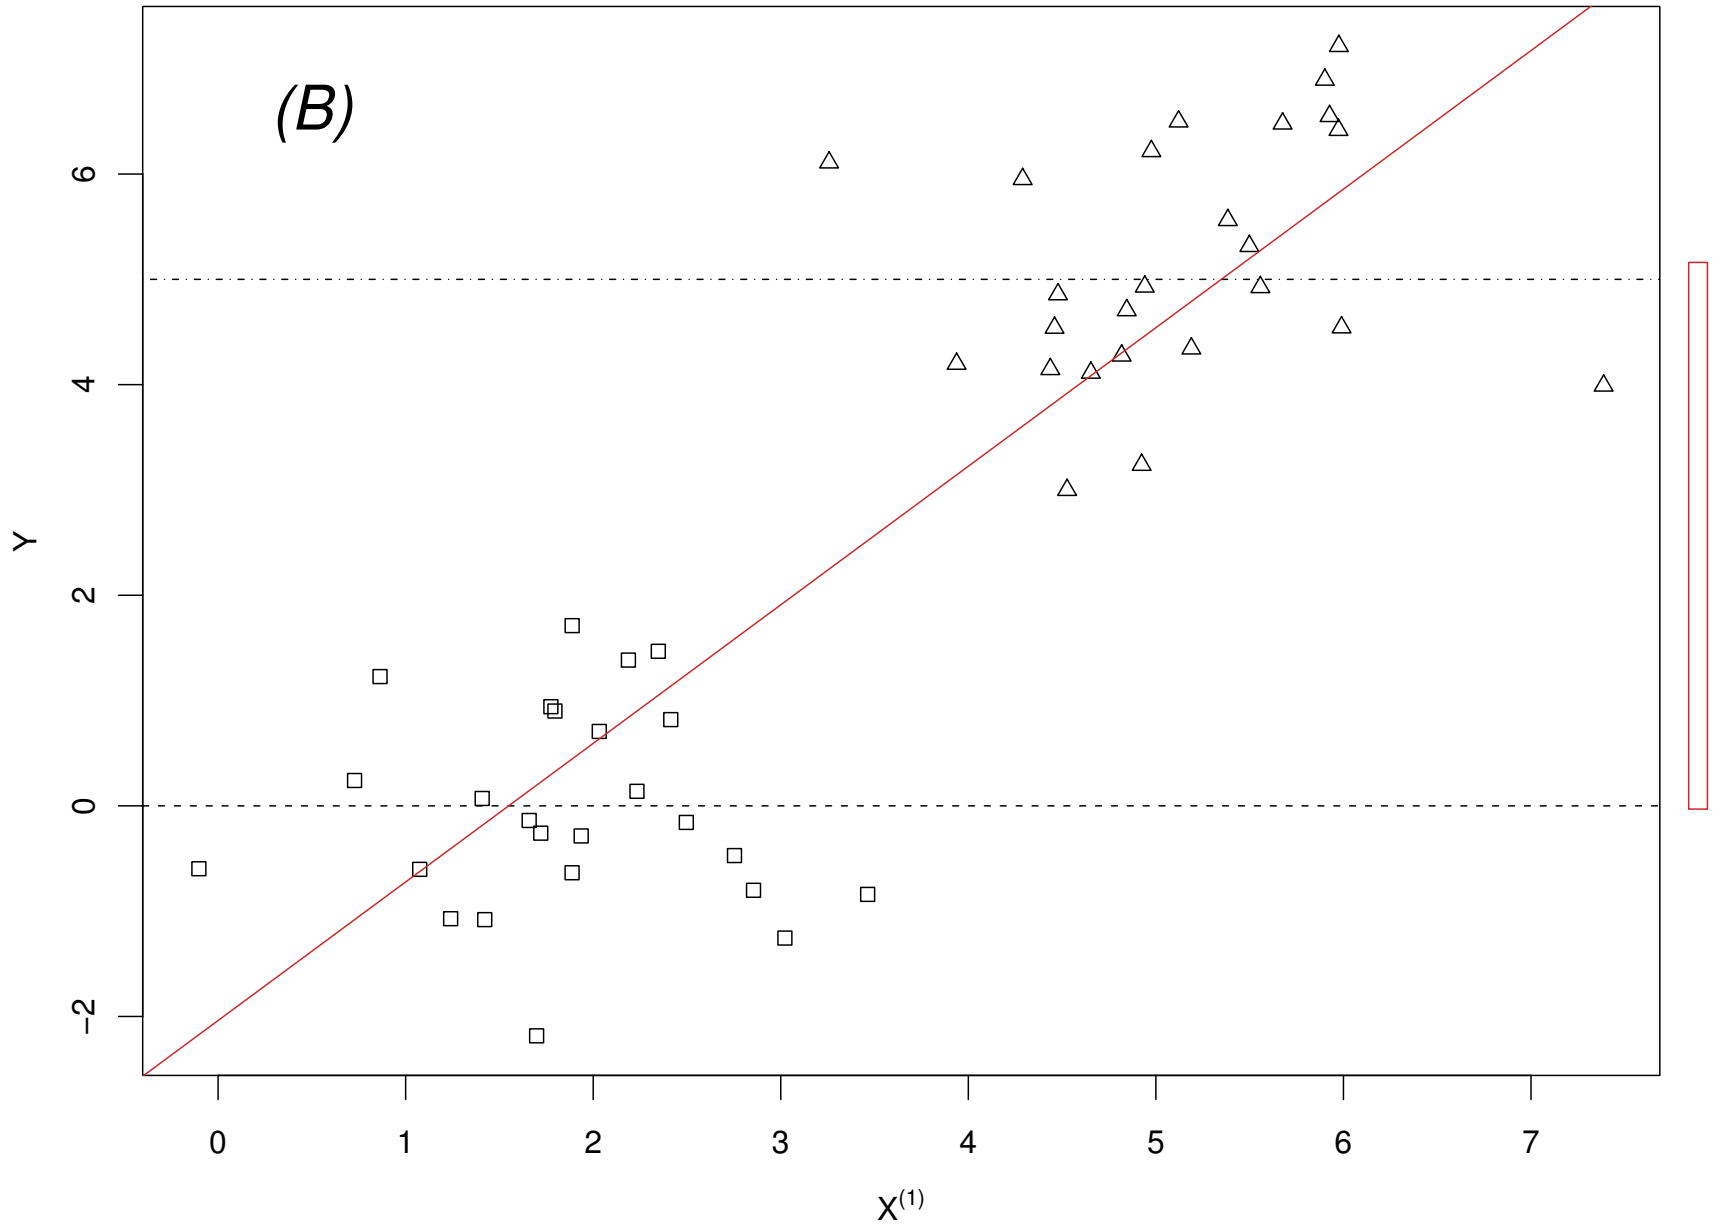
d Künstliches Bsp: Eine kontinuierliche $X^{(1)}$ und eine binäre $X^{(2)}$.

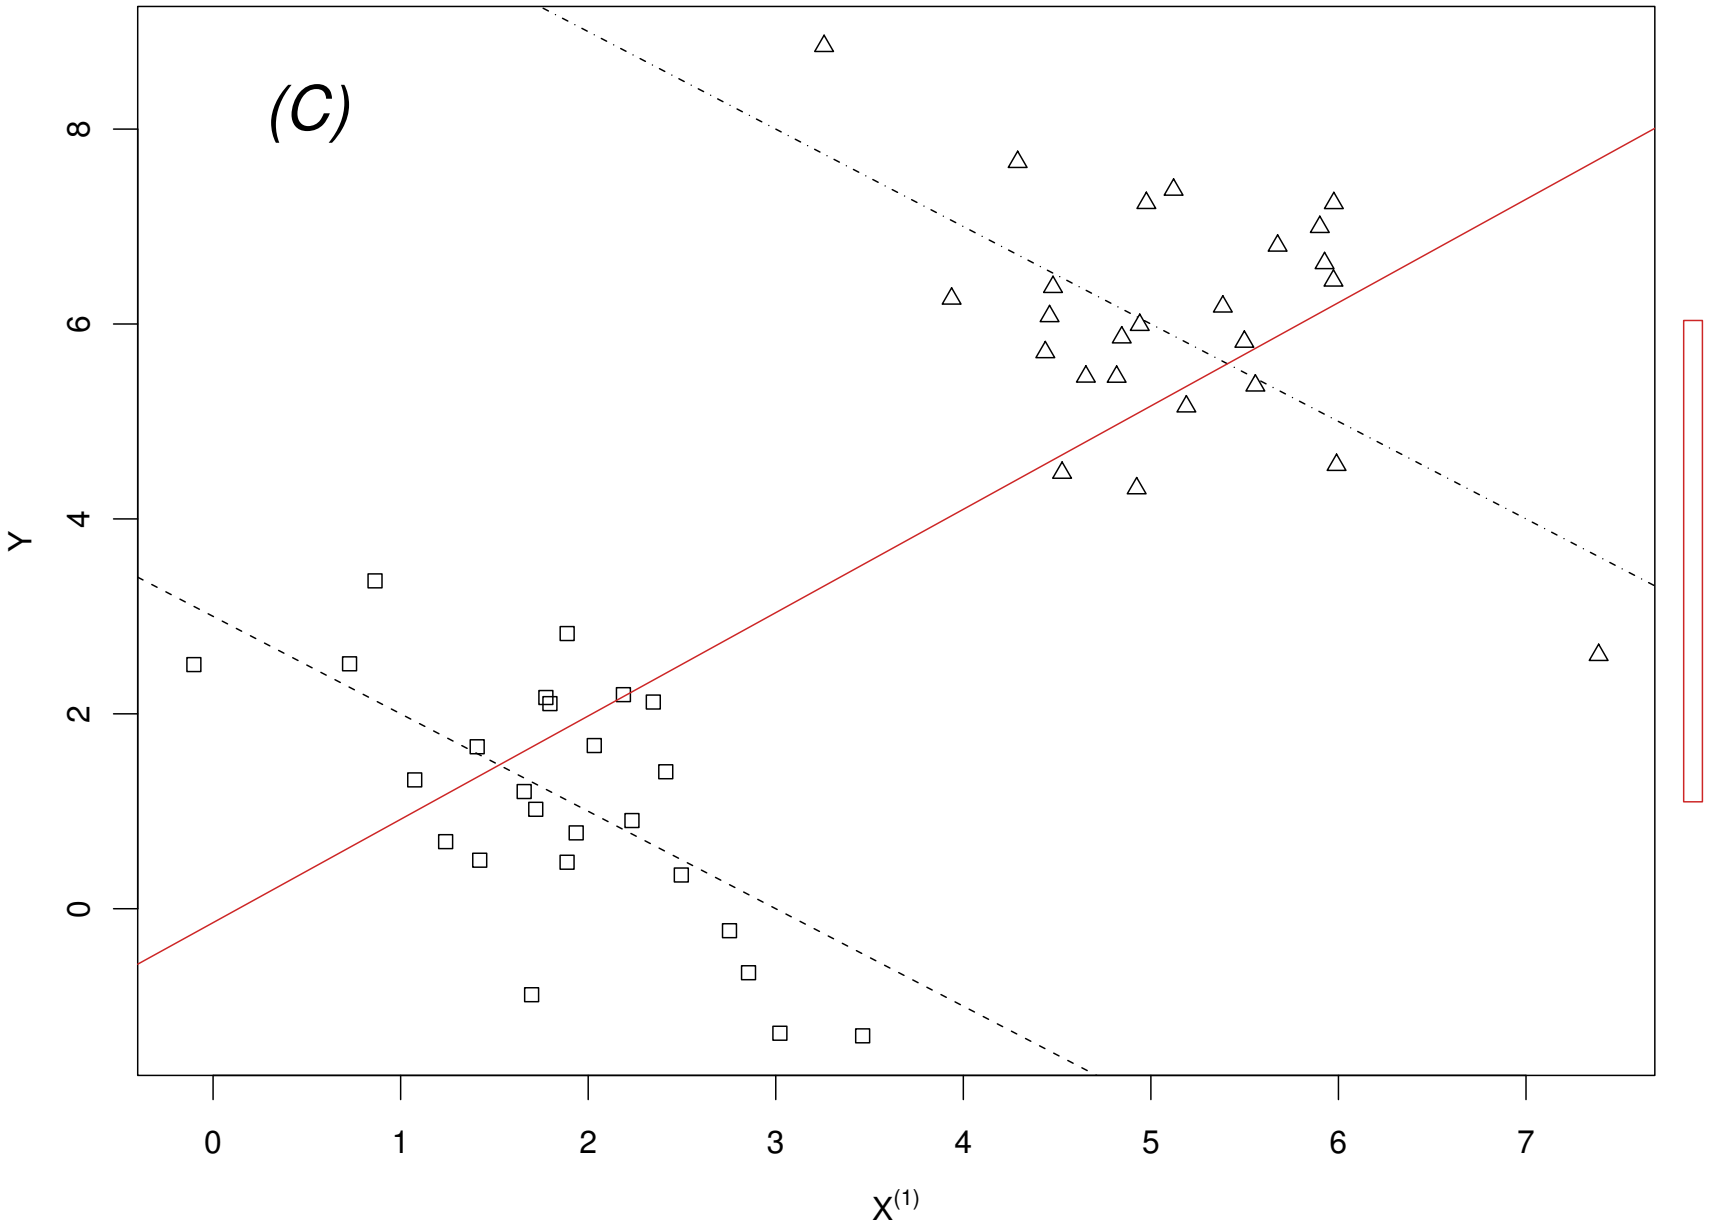

(A)
Y
0
2
4
6
0
1
2
3
4
5
6
7
X(1)

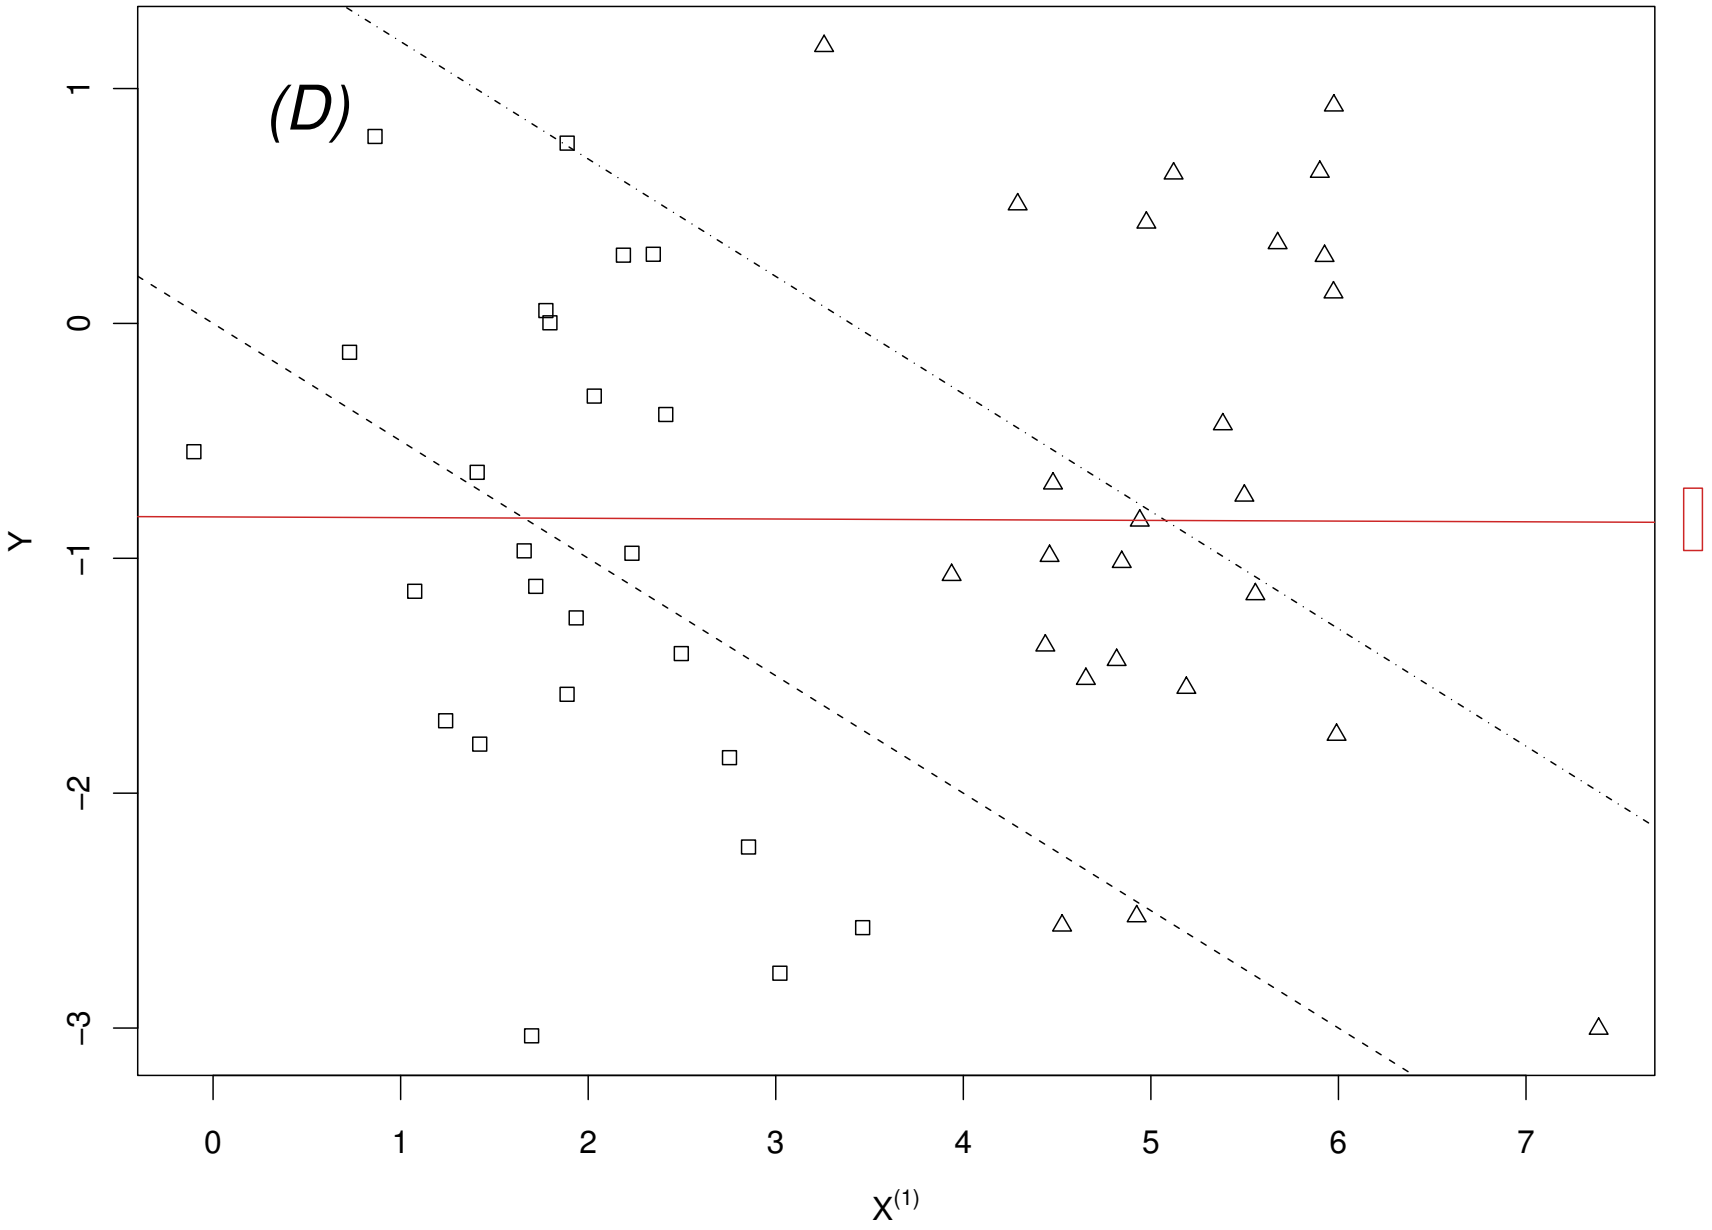

(A)
Y
0
2
4
6
0
1
2
3
4
5
6
7
X(1)
estimates from multiple model

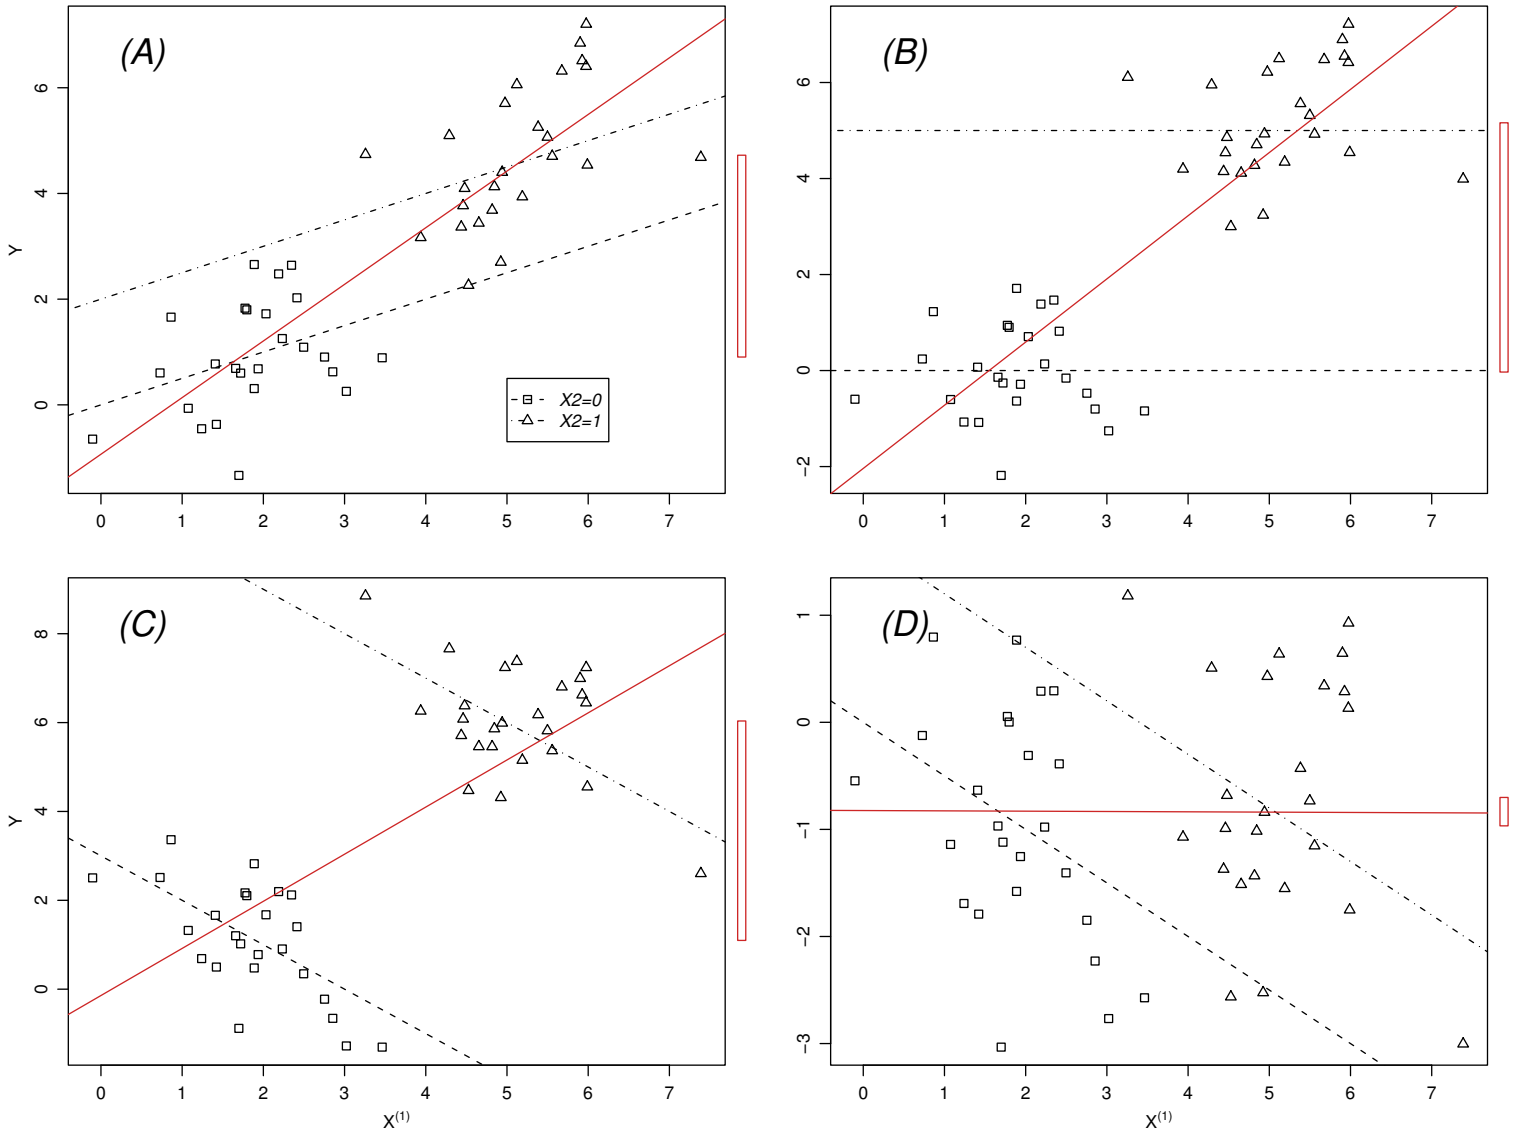

(A)
Y
$X^{(1)}$
0
1
2
3
4
5
6
7
0
2
4
6
estimates from simple models


(B)
Y
6
4
2
0
−2
0
1
2
3
4
5
6
7
X(1)
estimates from multiple model


(B)
Y
6
4
2
0
−2
0
1
2
3
4
5
6
7
X(1)


(C)
Y
0
2
4
6
8
0
1
2
3
4
5
6
7
X(1)


(D)
Y
1
0
−1
−2
−3
0
1
2
3
4
5
6
7
X(1)



Die Bedeutung der Regressionskoeffizienten hängt prinzipiell davon ab,
welche Eingangsgrössen im Modell auftreten!

3.3

e Ursache-Wirkungs-Beziehungen?!.

Indizien für solche Beziehungen sammeln!

β_j signifikant, Ursache-Wirkungs-Beziehung plausibel

$\longrightarrow$ „Nachweis" der Wirkung (?)

Achtung: indirekte Wirkungen sind möglich!

- $X^{(1)} \longrightarrow Z \longrightarrow Y$.
- $Z \longrightarrow X^{(1)}; Z \longrightarrow Y$.

Z im Modell $\longrightarrow$ keine indirekten Wirkungen.

$\longrightarrow$ „alle denkbaren" ursächlichen Var. ins Modell aufnehmen!

Besser:

- geplante Versuche,
- Nachweis eines Wirkungs-Mechanismus.

3.3

i β_j nicht signifikant $\longrightarrow$ kein Einfluss! ???

- Nullhypothese kann man nicht beweisen
- Ursächlicher Effekt kompensiert durch

gegensätzlichen Effekt einer korrelierten Einflussgrösse.

- Einfluss nicht-linear.

j Deshalb:

- möglichst alle möglichen ursächlichen Grössen

ins Modell aufnehmen,

- die Linearität der Zusammenhänge überprüfen

(s. Residuenanalyse),

- ein Vertrauensintervall für den Koeffizienten liefern

– statt eines P-Wertes.

3.3

k Indirekte Einflüsse können nicht vorkommen,
wenn $X^{(j)}$ und Z nicht zusammenhängen
(unkorreliert oder orthogonal sind).

Schätzung von β_j im multiplen und im einfachen Modell
sind dann gleich.

l Multiples Modell ist trotzdem sehr nützlich:
Kleinere Residuenstreuung $\widehat{\sigma}$
$\longrightarrow$ kürzere Vertrauensintervalle.

m Zusammenfassend: Ein multiples Regressionsmodell
sagt mehr aus als viele einfache Regressionen –
im Falle von korrelierten Eingangsgrössen viel mehr.

Merkpunkte

1. Die multiple lineare Regression bildet ein reichhaltiges Modell
   mit vielen Anwendungen.
2. Mit Transformationen, quadrat. Termen, Wechselwirkungen
   kann man nicht-lineare Beziehungen der Variablen modellieren!
3. Multiple Regression führt zu einer viel aussagekräftigeren Analyse
   als viele einfache Regressionen.
4. Mit Regression allein kann man keine Ursache – Wirkungsbeziehungen
   beweisen.

3.4 S-Funktionen

```
> r.lm <- lm(log10(ersch) ~ log10(dist),
a       data = d.spreng)
```

b Fehlende Werte

Einfachste Behandlung: Zeilen mit ≥ 1 fehlenden Wert weglassen.

```
lm(..., na.action=na.omit, ...)
```

c `summary(r.lm,cor=FALSE)`

wird gebraucht, um Resultate anzuschauen.

d `drop1(r.lm, test="F")` . Faktoren prüfen. F-Test.

! `anova` , `summary` für `aov` -Objekte macht andere Tests ...

3.4

e Funktion `regr.` Argumente wie `lm`

- braucht kein `summary`,
- prüft Faktoren ohne Aufruf von `drop1`,
- zeigt neue Grösse „signif", mit der man Vertrauensintervalle einfach berechnen kann,
- liefert weitere nützliche Grössen `stcoef` und `R2.x`,
- wird für viele weitere Modelle brauchbar sein.