Regressionsrechnung (Modul 1) Version 2021

Haben Sie nicht den Anspruch schon beim ersten Durchlesen der folgenden Einleitung alles zu verstehen. Vieles wird Ihnen erst beim Erarbeiten des Themas Regressionsrechnung klar werden.

Die Berechnungen der Regressionsgeraden und des Korrelationskoeffizienten sind informativ zu verstehen, d.h. Sie müssen die Formeln selber nicht anwenden können, sondern führen diese Berechnungen mit dem Rechner aus. Die Anleitungen dazu sind am Schluss der Berechnungen angegeben.

Unter den folgenden zwei Internetadressen finden Sie zwei Videos mit anschaulichen Erklärungen zu den Themen Streudiagramm und Korrelationskoeffizient .

Thema Streudiagramm:
https://www.youtube.com/watch?v=IwJ7RPIAxUo (Intervall: 0 bis 6.24 Minuten)

Thema Korrelationskoeffizient:
https://www.youtube.com/watch?v=IwJ7RPIAxUo (Intervall: 6.24 Minuten bis 13.24 Minuten)
https://www.youtube.com/watch?v=z7Ldw5an0Q0

1. Einleitung

Ein zentrales Anliegen in der Wissenschaft ist die Suche nach Zusammenhängen oder Trends zwischen zwei oder mehreren Merkmalen. Von besonderem Interesse sind lineare Zusammenhänge. Die Module 1 und 2 beschränken sich auf zwei quantitative Merkmale (Merkmale, die mit einer Einheit verbunden sind). Sie werden auch metrische Merkmale genannt, deren Zusammenhang untersucht werden soll.

Dabei gehen wir von Daten aus, die in einer Tabelle übersichtlich protokolliert sind. Aus der Übertragung in ein Koordinatensystem entsteht das zugehörige „Streudiagramm“. Falls die so entstandene „Datenwolke“ einen linearen Zusammenhang vermuten lässt, wird dieser mit einer optimalen Ausgleichsgerade, sog. Regressionsgerade erfasst. Die Abweichungen (Residuen) der Datenpunkte von der Regressionsgeraden werden im Residuendiagramm erfasst und dient der Beurteilung der Güte der Anpassung. Über die Stärke des linearen Zusammenhangs gibt der sogenannte Korrelationskoeffizient Auskunft.

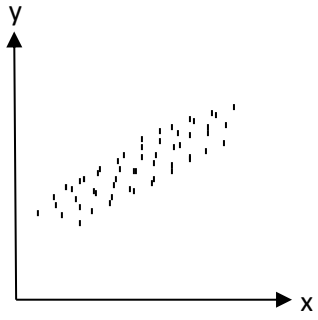
Die Regressionsrechnung ist ein „mathematisches Werkzeug“, das interdisziplinär in allen Bereichen Anwendung findet.

Modul 1 vermittelt an einem Beispiel das mathematische Grundwissen der Regressionsrechnung für lineare Zusammenhänge, d.h. die Themen Streudiagramm, Regressionsgerade, Korreationskoeffizient und Residuendiagramm. An einem Übungsbeispiel (Erfolgskontrolle) wird das Wissen vertieft.

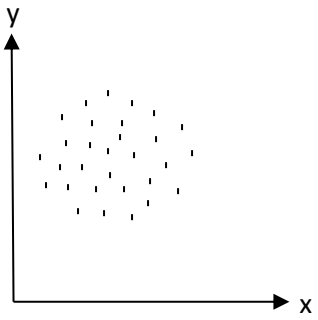
Im Modul 2 wird die lineare Regressionsrechnung interdisziplinär in verschiedenen Bereichen aus vorhandenen Daten angewandt und die Resultate interpretiert.

2. Streudiagramm

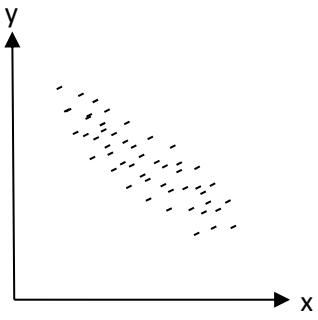
Richtung des statistischen Zusammenhangs zweier metrischer Merkmale an drei Beispielen.



Gleichsinniger Zusammenhang.
Wächst x, dann wächst auch y.



Kein Zusammenhang
zwischen x und y



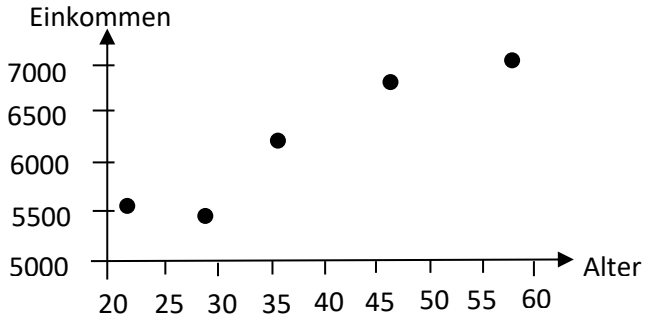
Gegensinniger Zusammenhang.
Hier fällt y mit steigendem x.

Diese Darstellung wird als **Streudiagramm** bezeichnet.

Beispiel

Von fünf Arbeitern wurden das Alter und das Einkommen in einer Tabelle erfasst und im Koordinatensystem das Einkommen in Anhängigkeit vom Alter dargestellt.

Arbeiter	Alter	Einkommen
A	21	5550
B	46	6800
C	58	7000
D	35	6200
E	28	5400



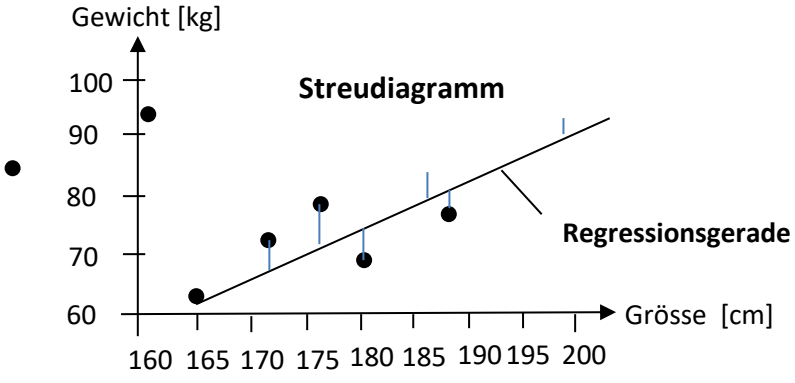
Das Streudiagramm zeigt, dass mit zunehmendem Alter auch das Einkommen steigt und lässt einen linearen gleichsinnigen Zusammenhang zwischen Alter und Einkommen vermuten.

3. Regressionsgerade

Lässt sich aus dem Zusammenhang des Streudiagrammes ein linearer Zusammenhang vermuten, so bestimmt man die Gerade, die sich im Streudiagramm von allen möglichen Geraden am besten dem Datenpunktverlauf anpasst. Im einfachsten Fall geschieht dies nach Augenmass, durch einzeichnen einer Geraden, die von den Datenpunkten möglichst wenig abweicht. Die Funktion der als **Regressionsgerade** bezeichneten Geraden bestimmen wir, indem wir die vertikalen Abstände der Punkte eines Streudiagramms zu jeder möglichen Geraden erfassen und dann unter den unendlich vielen Geraden, jene als Regressionsgerade auswählt, welche die kleinste Summe der quadrierten Abstände (Abweichungen der Datenpunkte von der Regressionsgeraden sog. Residuen) aufweist, sog. Methode der kleinsten Quadrate. Mathematisch wird diese besondere Gerade als Lösung einer Extremwertaufgabe gefunden.

Zusammenhang zwischen Gewicht und Körpergrösse von Sportlern

Grösse [cm]	Gewicht [kg]
165	62
172	71
176	79
180	68
186	84
187	77
198	92



Eingabe lineare Regressionsrechnung y = mx + q

Eingabe für CASIO fx-991ES PLUS

MODE	3	2

x- und y-Werte eingeben und jeweils mit = abschliessen.

Wenn alle x- und y-Werte eingegeben sind mit AC abschliessen.

Ausgabe des Ordinatenabschnitts A = q

SHIFT	1	5	1	**=**	**A**

Ausgabe des Steigungsfaktors B = m

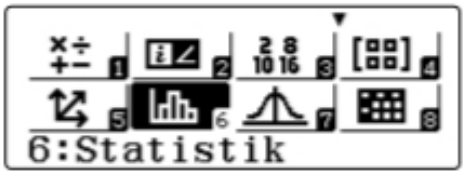
SHIFT	1	5	2	**=**	**B**

Ausgabe des Korrelationsfaktors „r“

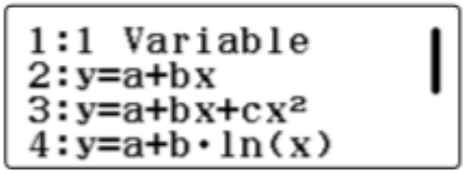
SHIFT	1	5	3	**=**	**r**

Eingabe für CASIO fx-991DE X

Anwendung 6 Statistik auswählen.



Auswahl 2, die lineare Funktion auswählen.



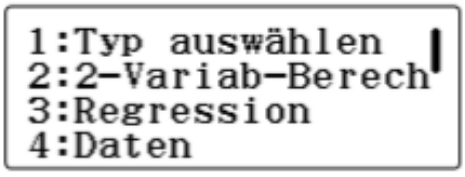
x- und y-Werte eingeben und jeweils

mit = abschliessen.
Wenn alle x- und y-Werte eingegeben

sind mit AC abschliessen.

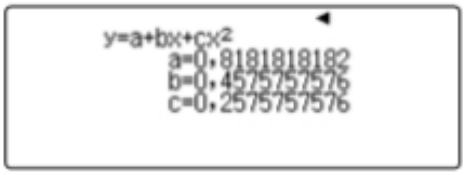


Über OPTN wählen Sie 3 Regression.



Die gewünschten Kennwerte a, b und r

werden angezeigt.



Beispiel CASIO fx-991ES PLUS

Eingabe

MODE	3	2

165	=	↑	→	62	=	←	172	=	↑	→	71	=	←											
176	=	↑	→	79	=	←	180	=	↑	→	68	=	←											
186	=	↑	→	84	=	←	187	=	↑	→	77	=	←	198	=	↑	→	92	=	←	AC			

Ausgabe des Ordinatenabschnitts „q“

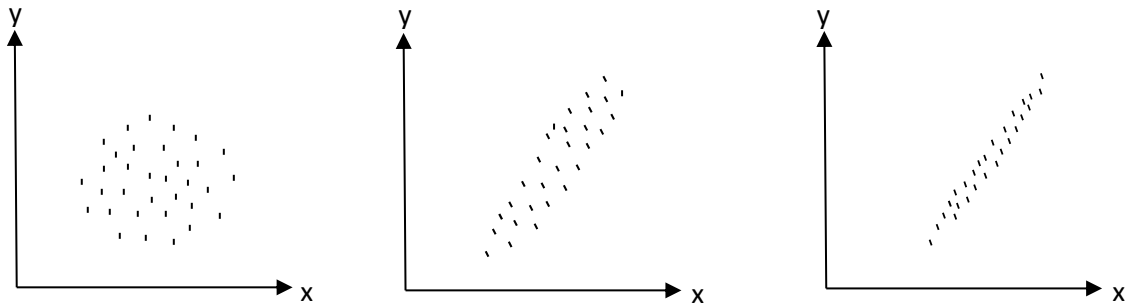
SHIFT	1	5	1	**=**	**-71.12**

Ausgabe des Steigungsfaktors „m“

SHIFT	1	5	2	**=**	**0.816**

Achtung! Der Rechner verwendet für die lineare Funktionsgleichung an Stelle von der gewohnten Form y = mx + q die Form **y = A + BX.** Darin entspricht „A“ dem Ordinatenabschnitt „q“ und „B“ dem Steigungsfaktor „ m“.

5. Der Korrelationsfaktor r



Im linken Streudiagramm erkennen wir keinen Zusammenhang der Merkmale x und y. In den beiden anderen Streudiagrammen besteht ein gleichsinniger Zusammenhang. Hinsichtlich seiner Stärke wächst der Zusammenhang in den Abbildungen von links nach rechts.

Der **Korrelationsfaktor r** ist ein Mass für die Stärke und Richtung des linearen Zusammenhangs zwischen den Datenpunkten zweier quantitativer Merkmale. Je dichter die Punktewolke auf der noch zu berechnenden Regressionsgeraden liegt, je stärker ist der lineare Zusammenhang.

Richtung: Wenn r > 0 steigt die zugehörige Regressionsgerade, wenn r < 0 fällt die zugehörige Regressionsgerade.

Stärke: Bei |r| = 1 liegen alle Punkte auf der Regressionsgerade, d.h. vollständiger Zusammenhang.

Als **Faustregel** gilt:

$0 \leq |r| \leq 0.2$ schwacher Zusammenhang
$0.2 < |r| \leq 0.6$ mittlerer Zusammenhang
$0.6 < |r| < 1$ starker Zusammenhang
$|r| = 1$ vollständiger Zusammenhang

Mit dem CASIO fx-991ES PLUS berechnet:

Eingabe

MODE	3	2

165	=	↑	→	62	=	←	172	=	↑	→	71	=	←

176	=	↑	→	79	=	←	180	=	↑	→	68	=	←

186	=	↑	→	84	=	←	187	=	↑	→	77	=	←	198	=	↑	→	92	=	←	AC

Ausgabe des Korrelationsfaktors „r“

SHIFT	1	5	3	=	**0.877**

Beispiel TI-nspire cx

Eingabe

[Dokumente]

→ Punkt 1 Neues → Punkt 4 Lists & Spreadsheet

Es erscheint eine Liste (Tabellenblatt)

In den Listenkopf für die Spalte der x-Werte bei A“ l1“, Für die Spalte der y-Werte“ l2“ eintragen

Die x- und y-Werte eingeben

[menu]

→ Punkt 4 Statistik → Punkt 1 Statistische Berechnungen → Punkt 3 Lineare Regression (mx + b)

Im sich öffnenden Fenster mit dem Cursor für x-Werte l1 und für die y-Werte l2 auswählen

ok drücken

Ausgabe des Ordinatenabschnitts „q“, Steigungsfaktors „m“ und Korrelationsfaktors „r“

Das Ergebnis erscheint in der D-Spalte

4. Residuendiagramm

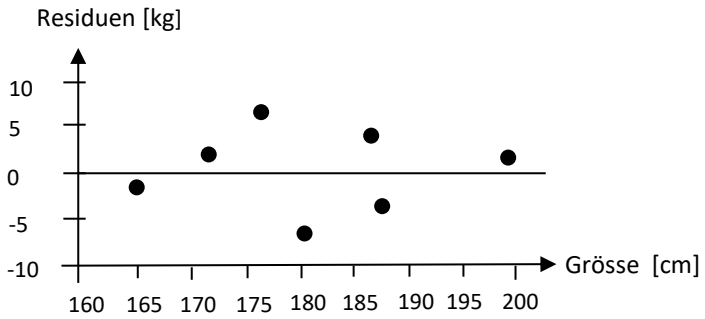
Aufschluss über die Stärke des linearen Zusammenhangs zwischen den Datenpunkten zweier quantitativer Merkmale kann auch aus dem Residuendiagramm gewonnen werden.

Dabei werden die vertikalen Abweichungen r_i (Residuen) der einzelnen Daten y_i , der Regressionsgeraden $y = mx + q$ für jeden Wert x dargestellt: $r_i = y_i – (mx + q)$.

Schwanken die Residuen r_i unregelmässig und nahe am Wert Null, so liegt eine gute Anpassung an die Regressionsgerade vor. Andernfalls ist die Anpassung an die lineare Funktion zu hinterfragen.

i	Grösse x_i	Gewicht y_i	$y = 0.816x – 71.12$	$r_i = y_i – y$
1	165	62	63.52	-1.52
2	172	71	69.232	1.768
3	176	79	72.496	6.504
4	180	68	75.76	-7.76
5	186	84	80.656	3.344
6	187	77	81.472	-4.472
7	198	92	90.448	1.552

Residuendiagramm



5. Zusammenfassung

Zwischen zwei quantitativen Merkmalen „x“ und „y“ vermuten wir einen linearen Zusammenhang.

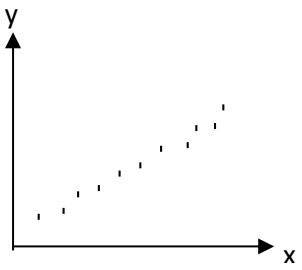
Ziel: Wir möchten die Beziehung bezüglich einem linearen Zusammenhang untersuchen und wenn zutreffend beschreiben.

Vorgehen

1. Schritt: Zur Stützung der Vermutung werden die durch Messungen erfassten x- und y-Werte in einer Tabelle festgehalten.

Grösse [cm]	Gewicht [kg]
165	62
172	71
176	79
180	68
186	84
187	77
198	92

2. Schritt: Zur Tabelle wird ein Streudiagramm erstellt. Ein Paar (xIy) von Messwerten erscheint als Punkt im Diagramm und bilden mit den anderen Punkten eine gleichsinnige „Punktwolke“

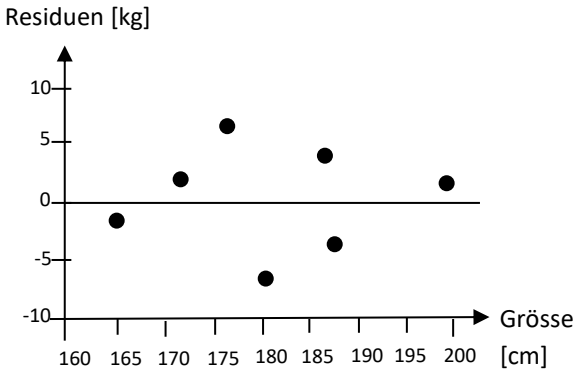


3. Schritt: Regressionsgerade y = mx + q berechnen, so dass die Summe der Quadrate der Residuen minimal wird.

m = 0.816
q = -71.12
$\Rightarrow$ y = 0.816x – 71.12

4. Schritt: Zur Beurteilung der Güte der Anpassung an die lineare Funktion den Korrelationskoeffizient berechnen und das Residuendiagramm erstellen.

R = 0.877



5. Schritt: Interpretation und Auswertung.

Fehlende y-Werte können berechnet werden.
In der Nähe des erhobenen Datenbereichs können Prognosen (Trends) erstellt werden, insbesondere bei Zeitreihen.

Schlussfolgerung: Mit hoher Wahrscheinlichkeit gibt es einen linearen Zusammenhang zwischen Körpergrösse und dem Körpergewicht der untersuchten Sportler.
Körpergewicht [kg]≈ 0.82 · Grösse [cm] – 71.12

6. Erfolgskontrolle

Die folgende Aufgabe dient als Erfolgskontrolle

Ein Unternehmer möchte erfahren, ob seine Marketingaktivitäten erfolgreich sind.

Eine Stichprobe von zehn zufällig ausgewählten Monatsumsätzen mit den zugehörigen Marketingausgaben (in Tausend Fr.) ist in der folgenden Tabelle zusammengestellt

Marketingausgaben x	24	15	19	26	14	17	20	13	18	21
Umsatz y	200	185	221	240	183	162	186	149	181	211

a) Erstellen Sie das zugehörige Streudiagramm

b) Berechnen Sie mit Hilfe des Rechners die Regressionsgerade und den Korrelationskoeffizient.

c) Zeichnen Sie die Regressionsgerade in das Streudiagramm ein.

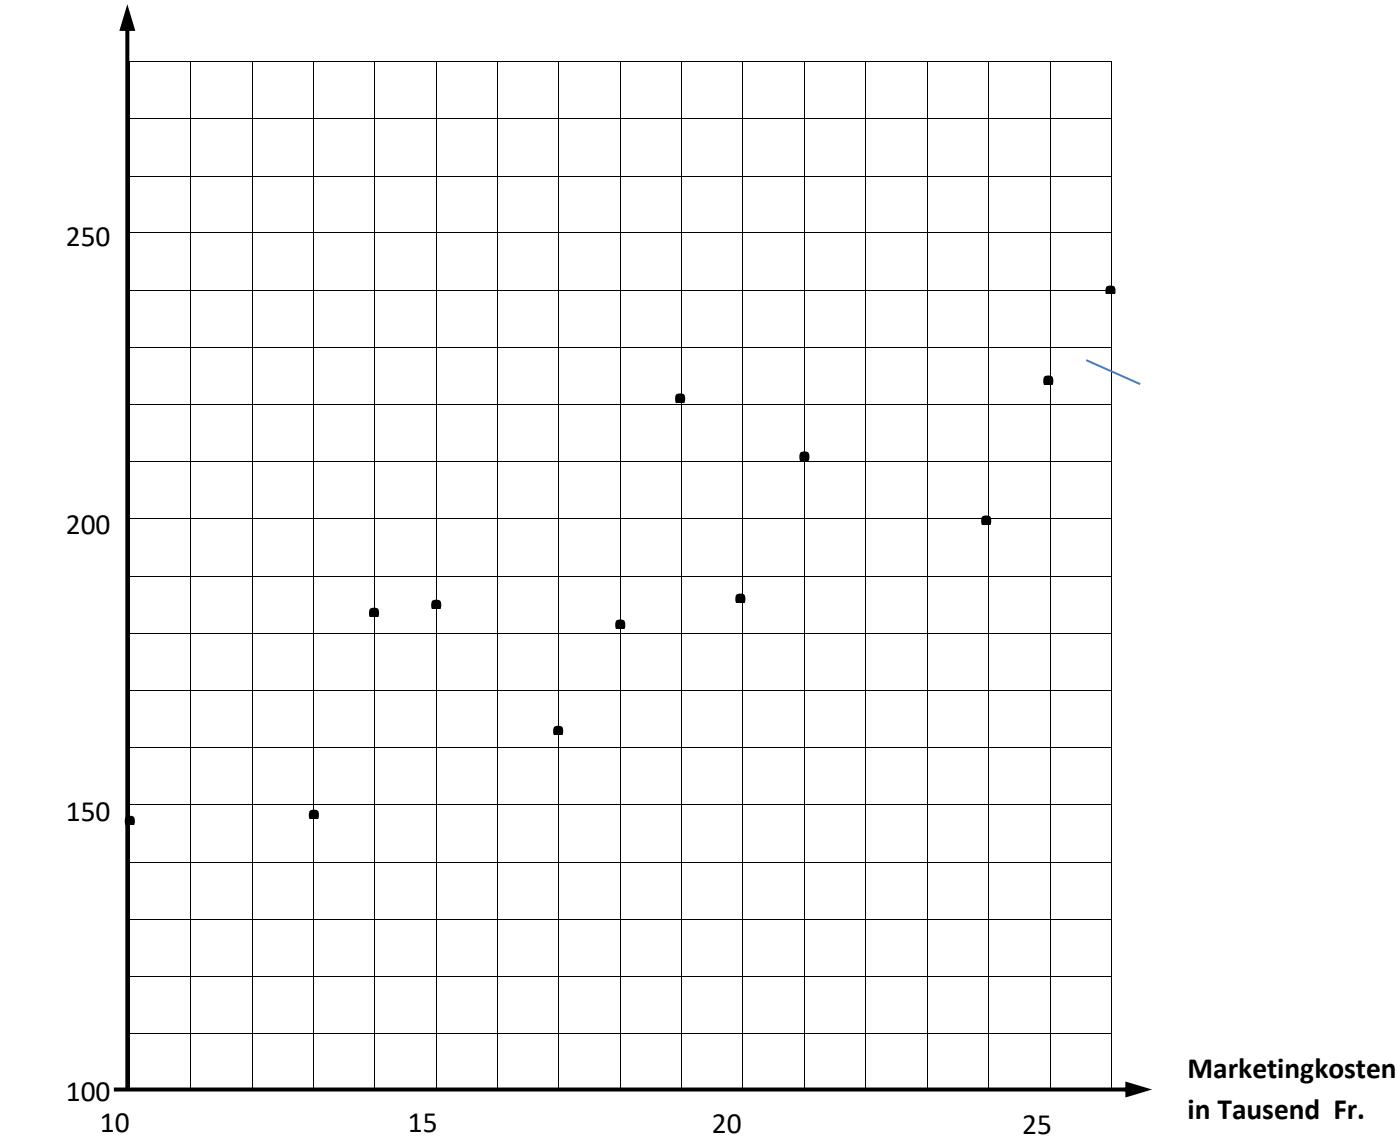
d) Welchen Umsatz würden Sie erwarten, wenn kein Marketing betrieben würde?

e) Welchen Umsatz würden Sie bei einem Marketingaufwand von Fr. 22000.- erwarten?

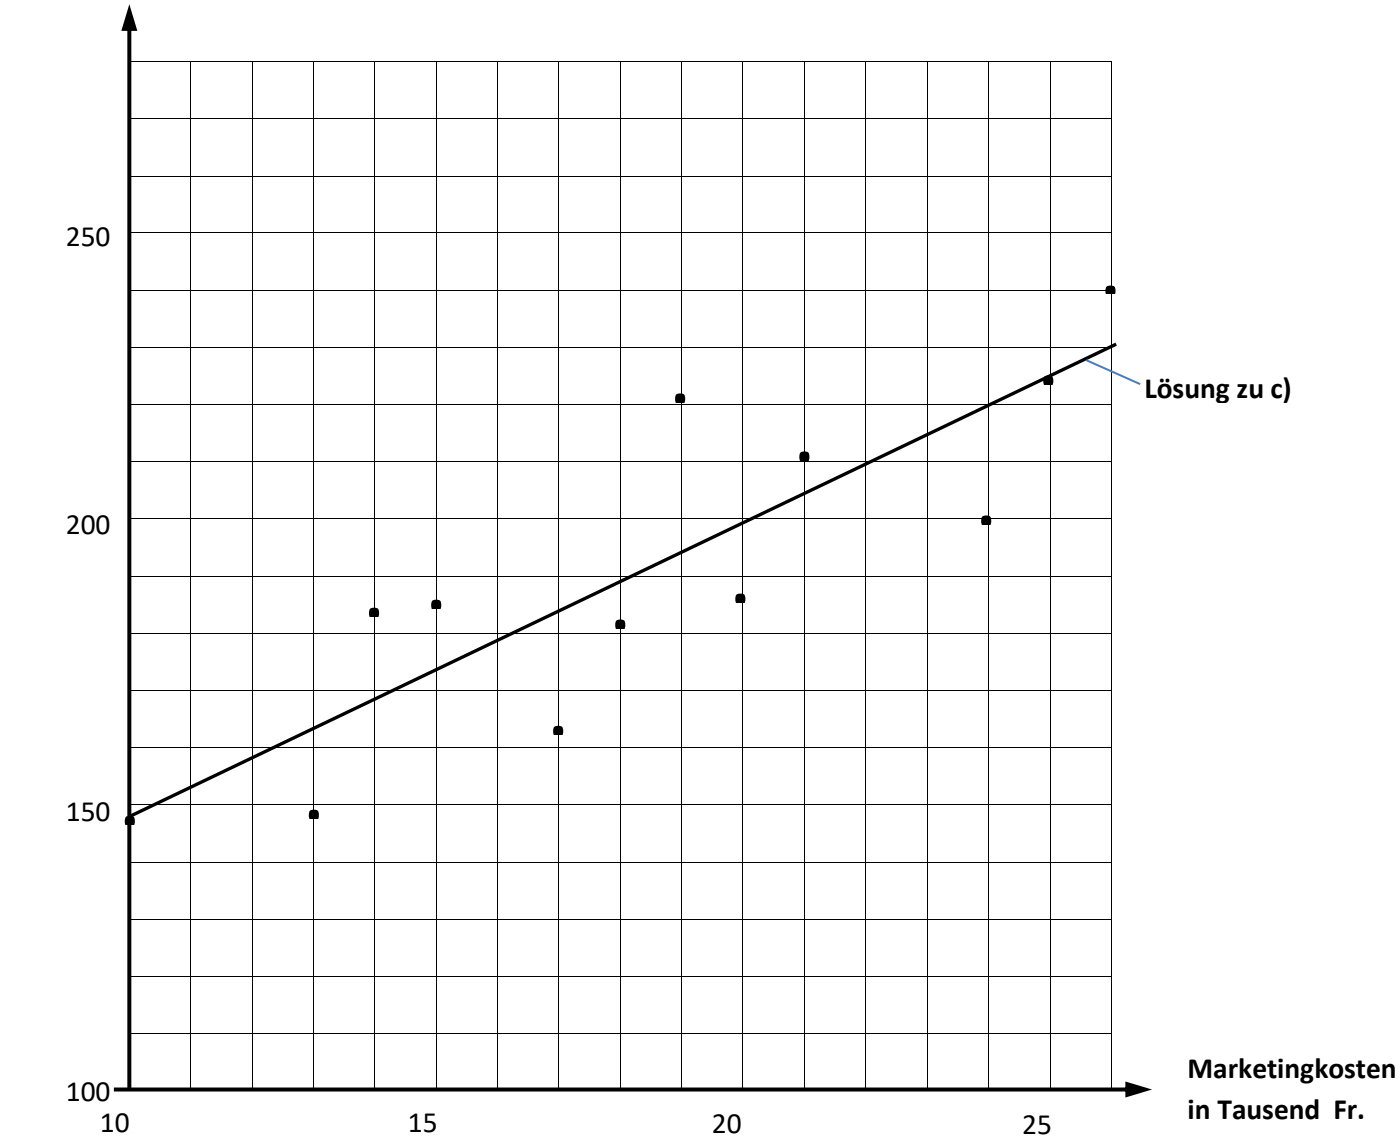
f) Erstellen Sie das zugehörige Residuendiagramm.

g) Beurteilen Sie die Stärke des linearen Zusammenhangs.

Lösung zu a)


Umsatz in Tausend Fr.
250
200
150
100
10
15
20
25
Marketingkosten in Tausend Fr.

Lösung zu a)


Umsatz in Tausend Fr.
250
200
150
100
10
15
20
25
Lösung zu c)
Marketingkosten in Tausend Fr.

Lösung zu b)

MODE	3	2

13	=	↑	→	149	=	←	14	=	↑	→	183	=	←
15	=	↑	→	185	=	←	17	=	↑	→	162	=	←
18	=	↑	→	181	=	←	19	=	↑	→	221	=	←
20	=	↑	→	186	=	←	21	=	↑	→	211	=	←
24	=	↑	→	200	=	←	26	=	↑	→	240	=	←	AC

Ausgabe des Ordinatenabschnitts „q“

SHIFT	1	5	1	=	**97.26**

Ausgabe des Steigungsfaktors „m“

SHIFT	1	5	2	=	**5.056**

Ausgabe des Korrelationsfaktors „r“

SHIFT	1	5	3	=	**0.787**

Die **Funktion der Regressionsgerade** lautet: **5.056x + 97.26**

Der **Korrelationsfaktor** beträgt: **0.787**

Lösung zu d)

Bei x = 0 (Marketingkosten = 0) würden wir einen **Umsatz** y von **Fr. 97260.-** erwarten.

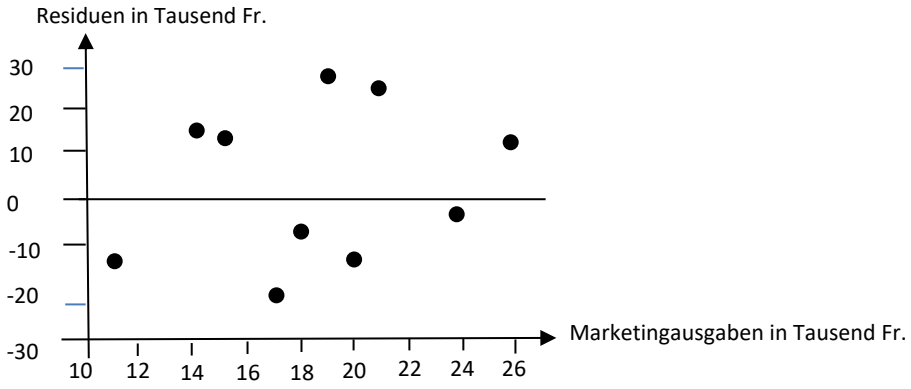
Lösung zu e)

Bei x = 22 (einen Marketingaufwand von Fr. 22000.-) würden wir einen **Umsatz** von:
y = 5.056·22 + 97.26 = 208.492, d.h. **Fr. 208492.-** erwarten.

Lösung zu f)

i	Grösse x_i	Gewicht y_i	$y = 5.056x + 97.26$	$r_i = y_i - y$
1	13	149	162.988	-13.988
2	14	183	168.044	14.956
3	15	185	173.1	11.9
4	17	162	183.212	-21.212
5	18	181	188.268	-7.268
6	19	221	193.324	27.676
7	20	186	198.38	-12.38
5	21	211	185.436	25.564
6	24	200	200.604	-0.604
7	26	240	228.716	11.284

Residuendiagramm



Lösung zu g)

Der relativ hohe Korrelationskoeffizient lässt auf einen starken linearen Zusammenhang schliessen.